

A foundation model for clinician-centered drug repurposing

Le-Van Thai

July 2026

1 Motivations


- Drug repurposing là bài toán tìm ra các công dụng điều trị mới cho những thuốc đã được phê duyệt. Tuy nhiên, trong thực tế, quá trình này vẫn chủ yếu dựa trên các phát hiện tình cờ.
- Các phương pháp hiện nay thường giả định rằng bệnh cần dự đoán đã có sẵn thuốc điều trị trong dữ liệu huấn luyện. Do đó, các mô hình gặp khó khăn khi áp dụng cho những bệnh hiếm, bệnh có dữ liệu sinh học hạn chế hoặc hoàn toàn chưa có liệu pháp điều trị.
- Một chỉ định điều trị mới của thuốc có thể hoàn toàn khác với mục đích ban đầu khi thuốc được phát triển. Ví dụ, *Thalidomide* ban đầu được sử dụng để giảm triệu chứng ốm nghén ở phụ nữ mang thai, nhưng sau đó được tái định vị để điều trị đa u tủy (*multiple myeloma*).
- Vì vậy, các mô hình học máy cần có khả năng *zero-shot drug repurposing*, tức là dự đoán các ứng viên thuốc cho những bệnh chưa từng có thuốc điều trị hoặc có rất ít kiến thức sinh học. Tuy nhiên, hiệu năng của các phương pháp hiện tại giảm đáng kể trong các trường hợp này.

2 Contributions

- Paper đề xuất **TxGNN**, một *graph foundation model* dành cho bài toán *zero-shot drug repurposing*. Khác với các phương pháp xây dựng mô hình riêng cho từng bệnh, TxGNN là một mô hình nền tảng được tiền huấn luyện trên đồ thị tri thức y học, có khả năng dự đoán ứng viên tái định vị thuốc cho 17.080 bệnh, bao gồm cả những bệnh chưa có phương pháp điều trị.
- TxGNN được huấn luyện trên một *medical knowledge graph* quy mô lớn, bao gồm cơ chế bệnh của 17.080 bệnh và cơ chế tác động của 7.957 loại thuốc. Mô hình kết hợp **Graph Neural Network (GNN)** để học biểu

diễn các thực thể trong đồ thị và **Metric Learning** để chuyển giao tri thức từ các bệnh đã có thuốc điều trị sang các bệnh chưa có thuốc, cho phép dự đoán zero-shot mà không cần huấn luyện bổ sung.

- Tác giả đề xuất **TxGNN Explainer**, một mô-đun tạo các chuỗi suy luận nhiều bước (*multi-hop reasoning*) trên đồ thị tri thức nhằm giải thích cơ sở của từng dự đoán. Các đánh giá bởi chuyên gia cho thấy cả dự đoán và lời giải thích của TxGNN đều đạt kết quả tốt về độ chính xác, độ tin cậy và tính hữu ích.
- So với 8 phương pháp hiện có, TxGNN đạt hiệu quả cao hơn trong thiết lập zero-shot, với độ chính xác dự đoán chỉ định điều trị tăng đến 49.2% và chống chỉ định tăng đến 35.1%. Ngoài ra, nhiều dự đoán của TxGNN phù hợp với các trường hợp kê đơn ngoài chỉ định (*off-label prescriptions*) trong dữ liệu lâm sàng, cho thấy tiềm năng ứng dụng thực tế của mô hình.



Hình 1: Kiến trúc tổng quan của TxGNN. Mô hình sử dụng *medical knowledge graph* để dự đoán chỉ định hoặc chống chỉ định cho các cặp bệnh – thuốc trong thiết lập zero-shot, đồng thời sinh các chuỗi suy luận nhiều bước nhằm giải thích cơ sở của từng dự đoán.

3 Method

3.1 Thu thập và xây dựng bộ dữ liệu đồ thị tri thức y học

Phần lớn dữ liệu được sử dụng trong nghiên cứu được thu thập từ các kho tri thức y học công khai (*publicly available knowledge repositories*).

Đối với dữ liệu nội bộ, nghiên cứu đã được phê duyệt bởi hội đồng đạo đức nghiên cứu (*Institutional Review Board - IRB*). Trước khi thực hiện phân tích tính toán và phát triển mô hình, toàn bộ dữ liệu hồ sơ bệnh án điện tử

(*Electronic Medical Records - EMRs*) được ẩn danh (*de-identified*) nhằm bảo vệ quyền riêng tư của bệnh nhân. Bệnh nhân không được trực tiếp tuyển chọn hoặc tham gia vào nghiên cứu.

3.2 Medical Knowledge Graph (KG)


TxGNN được xây dựng dựa trên một đồ thị tri thức y học không đồng nhất (*heterogeneous medical knowledge graph*), trong đó bao gồm nhiều loại thực thể sinh học và nhiều loại quan hệ khác nhau.

Cụ thể, KG bao gồm:

- 10 loại nút (*node types*);
- 29 loại quan hệ cạnh không có hướng (*undirected edge types*).

Tổng cộng, đồ thị chứa:

- 123,527 nút (*nodes*);
- 8,063,026 cạnh (*edges*).



Hình 2: The TxGNN model trained on a medical KG of disease mechanisms across 17,080 diseases and drug mechanisms of action for 7,957 drugs.

3.3 Overview of TxGNN approach

TxGNN xem bài toán tái định vị thuốc như một bài toán dự đoán quan hệ (*relation prediction*) trên đồ thị tri thức y học.

Cho một đồ thị tri thức không đồng nhất:

$$G = (V, E, R)$$

trong đó V là tập các nút, E là tập các cạnh và R là tập các loại quan hệ. Mỗi nút thuộc một loại thực thể sinh học trong tập V_T và được biểu diễn bằng một vector embedding ban đầu $h_i^{(0)}$.

Mục tiêu của TxGNN là dự đoán xác suất tồn tại quan hệ giữa một cặp bệnh–thuốc, bao gồm:

- chỉ định điều trị (*indication*);
- chống chỉ định (*contraindication*).

Khác với các phương pháp chỉ học từ các cặp bệnh–thuốc đã biết, TxGNN khai thác cấu trúc của medical knowledge graph để đưa các tri thức tiên nghiệm (*inductive priors*) vào mô hình. Nhờ đó, mô hình có khả năng suy luận trên các bệnh chưa từng xuất hiện trong dữ liệu huấn luyện, cho phép thực hiện *zero-shot drug repurposing*.

TxGNN gồm bốn thành phần chính:

(1) Heterogeneous Graph Neural Network Encoder

Bộ mã hóa GNN không đồng nhất học biểu diễn của các thực thể trong đồ thị tri thức. Thông qua quá trình truyền thông tin trên đồ thị (*message passing*), mô hình tạo ra embedding cho các thực thể như bệnh, thuốc, gene, protein và phenotype, trong đó các thực thể có quan hệ sinh học tương tự sẽ có biểu diễn gần nhau trong không gian tiềm ẩn.

(2) Disease Similarity-based Metric Learning Decoder

Mô-đun này khai thác sự tương đồng giữa các bệnh để cải thiện biểu diễn cho các bệnh có dữ liệu hạn chế. Các bệnh chưa được nghiên cứu đầy đủ có thể nhận thông tin bổ sung từ các bệnh tương tự nhưng có nhiều kiến thức hơn, giúp TxGNN chuyển giao tri thức giữa các bệnh và thực hiện dự đoán zero-shot.

(3) All-relation Pretraining và Drug–Disease Fine-tuning

TxGNN được huấn luyện qua hai giai đoạn:

- **Pretraining:** mô hình học trên toàn bộ các loại quan hệ trong KG nhằm nắm bắt cấu trúc tổng quát của mạng sinh học.
- **Fine-tuning:** mô hình được tối ưu tập trung vào các quan hệ thuốc–bệnh nhằm cải thiện khả năng dự đoán chỉ định và chống chỉ định.

(4) Graph Explanatory Module

Sau khi dự đoán, TxGNN sử dụng mô-đun giải thích để tìm các cạnh quan trọng và các chuỗi suy luận nhiều bước (*multi-hop paths*) trong KG. Các đường suy luận này cung cấp cơ sở giải thích cho dự đoán của mô hình dưới dạng *interpretable rationale*.

3.4 Heterogeneous Graph Neural Network Encoder

Mục tiêu của encoder là học embedding cho từng nút trong medical knowledge graph, trong đó embedding chứa thông tin từ cấu trúc lân cận và các loại quan hệ sinh học.

Quá trình học biểu diễn được thực hiện thông qua nhiều lớp *message passing*. Ở mỗi lớp, TxGNN thực hiện ba bước:

1. truyền thông tin phụ thuộc vào loại quan hệ;
2. tổng hợp thông tin từ các nút lân cận;
3. cập nhật embedding của nút.

3.4.1 Relationship-specific Message Passing

Do medical KG là một đồ thị không đồng nhất (*heterogeneous graph*), các cạnh trong đồ thị không chỉ khác nhau về vị trí mà còn khác nhau về ý nghĩa sinh học.

Ví dụ, xét nút bệnh:

$$i = \text{Cancer}$$

Trong KG, Cancer có thể có nhiều loại quan hệ với các thực thể khác:

$$\text{Cancer} \xrightarrow{\text{associated_with}} \text{TP53}$$

$$\text{Cancer} \xrightarrow{\text{treated_by}} \text{Aspirin}$$

$$\text{Cancer} \xrightarrow{\text{has_phenotype}} \text{Tumor growth}$$

Các quan hệ này mang ý nghĩa khác nhau:

- *associated_with*: mô tả cơ chế sinh học giữa bệnh và gene;
- *treated_by*: mô tả mối liên hệ điều trị giữa thuốc và bệnh;
- *has_phenotype*: mô tả biểu hiện lâm sàng của bệnh.

Vì vậy, TxGNN không sử dụng một phép biến đổi chung cho tất cả cạnh, mà học một phép biến đổi riêng cho từng loại quan hệ r .

Cụ thể, với một nút hàng xóm j , message được tạo ra:

$$m_{r,j}^{(l)} = W_{r,M}^{(l)} h_j^{(l-1)}$$

trong đó:

- $h_j^{(l-1)}$ là embedding của nút j ở lớp trước;

- $W_{r,M}^{(l)}$ là ma trận biến đổi riêng của quan hệ r .

Ví dụ, giả sử embedding ban đầu của gene TP53 là:

$$h_{TP53}^{(l-1)} = [0.2, 0.5, 0.1]$$

Do TP53 liên kết với Cancer thông qua quan hệ:

$$r = associated_with$$

nên message được biến đổi bởi ma trận tương ứng:

$$W_{associated_with,M}^{(l)}$$

Sau phép biến đổi, ta thu được:

$$m_{associated_with,TP53}^{(l)} = [0.4, 0.8, 0.3]$$

Đây là thông tin mà TP53 truyền tới nút Cancer.

Ngược lại, nếu một thuốc như Aspirin liên kết với Cancer thông qua quan hệ:

$$r = treated_by$$

thì message được tính bằng một ma trận khác:

$$W_{treated_by,M}^{(l)}$$

Điều này giúp mô hình phân biệt:

$$TP53 \rightarrow Cancer$$

và

$$Aspirin \rightarrow Cancer$$

không phải cùng một loại thông tin.

3.4.2 Neighborhood Aggregation

Sau khi tạo message phụ thuộc vào từng quan hệ, TxGNN tổng hợp thông tin từ các nút lân cận (*neighborhood aggregation*).

Với nút i , tập hàng xóm không được xem là một tập duy nhất mà được chia theo từng loại quan hệ:

$$N_i^r$$

Ví dụ với:

$$i = Cancer$$

ta có:

$$N_i^{gene} = \{TP53, EGFR, BRCA1\}$$

$$N_i^{drug} = \{Aspirin, Metformin\}$$

$$N_i^{phenotype} = \{\text{Tumor growth, Inflammation}\}$$

Như vậy:

$$N_i^r$$

chỉ chứa các nút có cùng loại quan hệ r , thay vì gom tất cả hàng xóm của Cancer vào một nhóm.

Ví dụ, với quan hệ gene:

$$N_i^{gene} = \{TP53, EGFR, BRCA1\}$$

mỗi gene gửi một message:

$$m_{TP53}, m_{EGFR}, m_{BRCA1}$$

Cancer cần tổng hợp các message này thành một biểu diễn duy nhất. TxGNN sử dụng phép lấy trung bình:

$$\tilde{m}_{r,i}^{(l)} = \frac{1}{|N_i^r|} \sum_{j \in N_i^r} m_{r,j}^{(l)}$$

Ví dụ:

$$m_{TP53} = [1, 2]$$

$$m_{EGFR} = [3, 4]$$

$$m_{BRCA1} = [5, 6]$$

Khi đó:

$$\begin{aligned} \tilde{m}_{gene,Cancer} &= \frac{[1, 2] + [3, 4] + [5, 6]}{3} \\ &= [3, 4] \end{aligned}$$

Vector này biểu diễn thông tin tổng hợp từ các gene liên quan đến Cancer. Quá trình này được thực hiện riêng cho từng loại quan hệ:

$$\tilde{m}_{gene,Cancer}$$

$$\tilde{m}_{drug,Cancer}$$

$$\tilde{m}_{phenotype,Cancer}$$

Sau đó, TxGNN mới kết hợp thông tin từ tất cả quan hệ để cập nhật embedding của Cancer:

$$h_i^{(l)} = h_i^{(l-1)} + \sum_{r \in R} \tilde{m}_{r,i}^{(l)}$$

Nhờ cơ chế này, embedding cuối cùng của một bệnh có thể chứa đồng thời nhiều khía cạnh sinh học:

- cơ chế phân tử từ gene/protein;
- biểu hiện lâm sàng từ phenotype;
- thông tin điều trị từ thuốc;
- các mối quan hệ sinh học khác trong KG.

3.5 Training TxGNN deep graph models

Mục tiêu của quá trình huấn luyện TxGNN là học cách dự đoán sự tồn tại của một quan hệ giữa hai thực thể trong medical knowledge graph.

Đối với một cạnh:

$$e_{i,j} = (i, r, j)$$

mô hình dự đoán xác suất tồn tại của quan hệ r giữa hai nút i và j :

$$p_{i,r,j}$$

Trong đó, tập dữ liệu dương:

$$D^+$$

bao gồm các cặp thực thể đã tồn tại trong KG với nhãn:

$$y_{i,r,j} = 1$$

Ngược lại, tập dữ liệu âm: Ngược lại, tập dữ liệu âm:

$$D^-$$

được tạo bằng phương pháp negative sampling nhằm sinh ra các cặp thực thể không có quan hệ quan sát được trong KG với nhãn:

$$y_{i,r,j} = 0$$

Ví dụ, trong medical KG tồn tại quan hệ:

$$Drug = \text{Aspirin} \xrightarrow{\text{treated_by}} Disease = \text{Inflammation}$$

nên cặp:

$$(\text{Aspirin}, \text{treated_by}, \text{Inflammation})$$

được đưa vào tập dương:

$$D^+$$

với:

$$y = 1$$

Ngược lại, nếu KG không chứa cạnh:

$$Drug = \text{Aspirin} \xrightarrow{\text{treated_by}} Disease = \text{Lung cancer}$$

thì cặp này có thể được sử dụng làm một mẫu âm:

$$(\text{Aspirin}, \text{treated_by}, \text{Lung cancer})$$

với:

$$y = 0$$

Điều này giúp mô hình học được sự khác biệt giữa các cặp thuốc-bệnh đã biết có liên hệ và các cặp chưa có bằng chứng về quan hệ điều trị trong KG.

TxGNN tối ưu mô hình bằng Binary Cross-Entropy Loss

Trong đó, mục tiêu là tăng xác suất cho các quan hệ đúng và giảm xác suất cho các quan hệ không tồn tại.

Khác với các phương pháp hoàn thiện đồ thị tri thức (*knowledge graph completion*) truyền thống thường tối ưu trên toàn bộ các loại quan hệ trong KG, TxGNN cần giải quyết bài toán đặc thù hơn: dự đoán quan hệ thuốc-bệnh.

Nếu chỉ tập trung vào drug-disease relation ngay từ đầu, mô hình có thể bỏ qua các thông tin sinh học quan trọng được truyền qua các quan hệ khác trong KG.

Ví dụ:

$$Drug \rightarrow Protein \rightarrow Gene \rightarrow Disease$$

có thể cung cấp thông tin quan trọng cho việc suy luận khả năng điều trị.

Ngược lại, nếu tối ưu tất cả quan hệ như nhau trong toàn bộ quá trình, mô hình có thể gặp khó khăn trong việc học các đặc trưng chuyên biệt cho tái định vị thuốc.

Do đó, TxGNN sử dụng chiến lược:

Pretraining + Fine-tuning

3.5.1 Pretraining TxGNN

Ở giai đoạn pretraining, TxGNN không tối ưu riêng cho bài toán dự đoán thuốc-bệnh (*drug-disease prediction*). Thay vào đó, mục tiêu của giai đoạn này là học biểu diễn tổng quát cho toàn bộ đồ thị tri thức y học (*medical knowledge graph*).

Do đó, mô hình được huấn luyện trên tất cả các loại quan hệ trong KG, bao gồm nhiều dạng tương tác sinh học khác nhau như:

$$\begin{aligned}\text{Drug} &\xrightarrow{\text{targets}} \text{Protein} \\ \text{Gene} &\xrightarrow{\text{associated_with}} \text{Disease} \\ \text{Protein} &\xrightarrow{\text{participates_in}} \text{Pathway} \\ \text{Disease} &\xrightarrow{\text{has_phenotype}} \text{Phenotype} \\ \text{Exposure} &\xrightarrow{\text{associated_with}} \text{Disease}\end{aligned}$$

Medical KG của TxGNN có quy mô lớn với hơn:

- 8 triệu cạnh (*edges*);
- 120 nghìn nút (*nodes*).

Do đó, việc đưa toàn bộ KG vào mỗi lần cập nhật gradient sẽ gây:

- tiêu tốn nhiều bộ nhớ GPU;
- tăng đáng kể thời gian huấn luyện.

Để giải quyết vấn đề này, TxGNN sử dụng chiến lược *stochastic mini-batching*. Thay vì xử lý toàn bộ cạnh trong một lần, mô hình chia các cạnh trong KG thành nhiều mini-batch nhỏ:

Batch 1: 50,000 edges
↓
Batch 2: 50,000 edges
↓
Batch 3: 50,000 edges
↓
...

Sau khi toàn bộ các mini-batch được sử dụng, một epoch được hoàn thành.

Trong mỗi mini-batch, đầu vào của TxGNN là một tập các cạnh trong KG, ví dụ:

(Aspirin, targets, COX1)

(COX1, participates_in, Inflammation)

(Diabetes, has_phenotype, Hyperglycemia)

Mô hình sau đó dự đoán xác suất tồn tại của từng quan hệ:

$$p_{i,r,j}$$

và được tối ưu để phân biệt các cạnh thực sự tồn tại trong KG với các mẫu âm được tạo bởi negative sampling.

Trong giai đoạn pretraining:

- tất cả các loại quan hệ được xem xét như nhau;
- mô hình chưa tập trung đặc biệt vào quan hệ thuốc-bệnh;
- cơ chế bổ sung embedding bệnh dựa trên mức độ kết nối (*degree-adjusted disease augmentation*) chưa được kích hoạt.

Chỉ sau khi encoder đã học được các tri thức sinh học tổng quát từ toàn bộ KG, TxGNN mới chuyển sang giai đoạn fine-tuning, trong đó mô hình tập trung tối ưu khả năng dự đoán quan hệ:

Drug $\rightarrow$ Disease

cho bài toán tái định vị thuốc.

3.5.2 Fine-tuning TxGNN

Sau giai đoạn pretraining, encoder của TxGNN đã học được các biểu diễn ẩn giàu thông tin sinh học từ toàn bộ medical knowledge graph. Các embedding này phản ánh cấu trúc lân cận và mối quan hệ giữa các thực thể trong KG.

Ví dụ, embedding của thuốc Aspirin có thể gián tiếp chứa thông tin về:

Aspirin $\rightarrow$ Protein $\rightarrow$ Pathway $\rightarrow$ Disease

Do đó, trong giai đoạn fine-tuning, TxGNN sử dụng lại trọng số của encoder:

$$\theta_{encoder}^{fine} = \theta_{encoder}^{pretrain}$$

nhằm tận dụng các tri thức sinh học tổng quát đã được học trước đó. Ngược lại, các tham số của decoder DistMult được khởi tạo lại:

$$w_r^{fine} \neq w_r^{pretrain}$$

bởi vì decoder trong giai đoạn pretraining được tối ưu cho nhiều loại quan hệ khác nhau trong KG, trong khi mục tiêu của fine-tuning là dự đoán các quan hệ thuốc-bệnh.

Cụ thể, sau khi encoder tạo ra embedding cuối cùng cho thuốc và bệnh:

$$h_{drug}, h_{disease}$$

TxGNN sử dụng decoder DistMult để dự đoán xác suất tồn tại của một quan hệ giữa hai thực thể. Mỗi loại quan hệ r được biểu diễn bởi một vector tham số học được w_r . Điểm tương tác giữa thuốc i , bệnh j và quan hệ r được tính:

$$score(i, r, j) = \sum_k h_{i,k} w_{r,k} h_{j,k}$$

Trong đó, phép nhân Hadamard (element-wise multiplication):

$$h_i \odot w_r \odot h_j$$

tính mức độ tương thích theo từng chiều embedding giữa hai thực thể với loại quan hệ cần dự đoán. Sau đó, hàm sigmoid chuyển điểm số thành xác suất:

$$p_{i,j,r} = \sigma(score(i, r, j)) = \frac{1}{1 + \exp(-score(i, r, j))}$$

Giá trị $p_{i,j,r}$ biểu diễn xác suất tồn tại của quan hệ giữa hai thực thể, ví dụ:

$$p(\text{Aspirin}, \text{treats}, \text{Cancer})$$

hoặc

$$p(\text{Aspirin}, \text{contraindicated}, \text{Disease})$$

Trong giai đoạn fine-tuning, chỉ các cặp thuốc-bệnh được sử dụng để tính hàm mất mát. Tuy nhiên, toàn bộ KG vẫn được giữ nguyên trong quá trình message passing để encoder tiếp tục khai thác các quan hệ sinh học gián tiếp.

Ví dụ, khi dự đoán khả năng điều trị của một thuốc đối với một bệnh, mô hình vẫn có thể sử dụng thông tin thông qua chuỗi liên kết:

$$Drug \rightarrow Protein \rightarrow Gene \rightarrow Disease$$

Nhờ đó, embedding của thuốc và bệnh không chỉ phụ thuộc vào các cạnh drug-disease đã quan sát trực tiếp mà còn chứa thông tin từ toàn bộ mạng sinh học.

Ngoài ra, trong giai đoạn fine-tuning, TxGNN kích hoạt cơ chế *degree-adjusted inter-disease embedding*. Đây không phải là một loại quan hệ mới trong KG, mà là một cơ chế bổ sung thông tin giữa các bệnh dựa trên mức độ tương đồng về cấu trúc sinh học.

Trong medical KG, mỗi bệnh có một mức độ kết nối (*degree*), được xác định bởi số lượng cạnh liên kết với bệnh đó:

$$deg(i) = |N_i|$$

Trong đó N_i là tập các nút lân cận của bệnh i trong KG.

Các bệnh có degree thấp thường có ít thông tin sinh học quan sát được, ví dụ ít gene liên quan, ít phenotype hoặc ít quan hệ thuốc-bệnh đã biết. Do đó,

embedding của các bệnh này được tạo bởi GNN có thể kém đầy đủ hơn so với các bệnh có nhiều dữ liệu.

Để bổ sung thông tin cho các bệnh ít dữ liệu, TxGNN xây dựng một *disease signature vector* cho mỗi bệnh:

$$z_i$$

Vector này được tạo dựa trên:

- các nút lân cận của bệnh trong KG;
- cấu trúc topology của mạng lưới liên quan đến bệnh (*local disease-associated network topology*).

Ví dụ, hai bệnh:

$$Disease_A$$

và

$$Disease_B$$

có thể có các mạng lưới sinh học tương tự:

$$Disease_A \rightarrow Gene_1 \rightarrow Pathway_1$$

$$Disease_B \rightarrow Gene_1 \rightarrow Pathway_1$$

mặc dù giữa hai bệnh không tồn tại cạnh trực tiếp trong KG.

Mức độ tương đồng giữa hai bệnh được đo bằng cosine similarity:

$$Similarity(d_i, d_j) = \frac{z_i \cdot z_j}{\|z_i\| \|z_j\|}$$

Giá trị này phản ánh mức độ giống nhau về cơ chế sinh học giữa hai bệnh. Các bệnh có điểm tương đồng cao được xem là có khả năng chia sẻ kiến thức sinh học.

Ví dụ, một bệnh hiếm:

$$Rare\ Disease\ A$$

chỉ có một vài liên kết:

$$Rare\ Disease\ A \rightarrow Gene\ X$$

có thể có similarity cao với một bệnh đã được nghiên cứu nhiều:

$$Disease\ B$$

vì chúng cùng liên quan đến các gene hoặc pathway tương tự.

Khi đó, TxGNN tạo một embedding bổ sung từ các bệnh tương đồng:

$$h_i^{sim}$$

bằng cách tổng hợp embedding của các bệnh lân cận trong không gian bệnh dựa trên similarity.

Embedding cuối cùng của bệnh được điều chỉnh theo degree:

$$\hat{h}_i = c_i h_i^{sim} + (1 - c_i) h_i$$

Trong đó:

- h_i là embedding bệnh được tạo bởi heterogeneous GNN encoder;
- h_i^{sim} là embedding được truyền từ các bệnh có cơ chế tương tự;
- c_i là hệ số điều chỉnh phụ thuộc vào mức độ kết nối của bệnh.

Đối với các bệnh có ít thông tin trong KG:

$$deg(i) \downarrow \Rightarrow c_i \uparrow$$

mô hình ưu tiên sử dụng kiến thức từ các bệnh tương tự.

Ngược lại, với các bệnh có nhiều dữ liệu:

$$deg(i) \uparrow \Rightarrow c_i \downarrow$$

embedding gốc từ GNN được ưu tiên vì đã chứa đủ thông tin sinh học.

Ví dụ, khi dự đoán thuốc cho một bệnh mới chưa từng xuất hiện trong tập huấn luyện:

$$Disease_{new}$$

TxGNN có thể truyền thông tin từ các bệnh tương tự:

$$Disease_{new} \approx Disease_{known}$$

để tận dụng các kiến thức đã học về:

$$Disease_{known} \rightarrow Gene \rightarrow Pathway \rightarrow Drug$$

Nhờ đó, mô hình vẫn có thể tạo ra embedding giàu thông tin và dự đoán khả năng điều trị trong thiết lập *zero-shot drug repurposing*.

Hai giai đoạn pretraining và fine-tuning đều được huấn luyện theo phương pháp end-to-end. Mô hình đạt hiệu suất tốt nhất trên tập validation được lựa chọn để đánh giá trên tập test và thực hiện các phân tích downstream.

3.5.3 Generating multi-hop interpretable explanations

Sau khi hoàn tất quá trình huấn luyện, TxGNN có thể dự đoán xác suất tồn tại của quan hệ thuốc–bệnh thông qua encoder GNN và decoder DistMult. Tuy nhiên, mô hình chỉ đưa ra kết quả dự đoán mà không cho biết những thông tin nào trong medical knowledge graph đã được sử dụng để đưa ra quyết định.

Ví dụ, khi dự đoán:

(Aspirin, *treats*, Cancer)

TxGNN có thể dự đoán:

$$p = 0.93$$

nhưng không thể biết liệu dự đoán này chủ yếu dựa trên:

- các protein mà Aspirin tác động;
- các gene liên quan đến Cancer;
- các pathway sinh học trung gian;
- hay một tập hợp các quan hệ khác trong KG.

Do đó, TxGNN sử dụng GraphMask để tìm ra những cạnh thực sự quan trọng đối với từng dự đoán.

GraphMask chỉ được huấn luyện sau khi TxGNN đã hoàn tất quá trình pretraining và fine-tuning.

Lúc này, toàn bộ encoder và decoder của TxGNN được giữ cố định (*freeze*):

$$\theta_{encoder}^{GraphMask} = \theta_{encoder}^{TxGNN}$$

$$\theta_{decoder}^{GraphMask} = \theta_{decoder}^{TxGNN}$$

GraphMask không học lại nhiệm vụ dự đoán thuốc–bệnh mà chỉ học cách xác định những message nào trong quá trình message passing thực sự cần thiết để duy trì dự đoán của TxGNN.

Ý tưởng chính Giả sử TxGNN đã dự đoán:

(Aspirin, *treats*, Cancer)

với xác suất:

$$p = 0.93$$

GraphMask sẽ chạy lại chính mô hình TxGNN nhiều lần.

Ở mỗi lần chạy, GraphMask thử loại bỏ một số message được truyền qua các cạnh trong KG rồi quan sát xem kết quả dự đoán thay đổi bao nhiêu.

Nếu sau khi bỏ một cạnh mà dự đoán gần như không thay đổi, cạnh đó được xem là không quan trọng.

Ngược lại, nếu việc loại bỏ một cạnh làm xác suất dự đoán giảm đáng kể, cạnh đó được xem là bằng chứng quan trọng đối với quyết định của mô hình.

Ví dụ:

$$0.93 \longrightarrow 0.92$$

sau khi loại bỏ một cạnh.

Sự thay đổi rất nhỏ cho thấy cạnh này hầu như không ảnh hưởng đến dự đoán.

Trong khi đó:

$$0.93 \longrightarrow 0.34$$

cho thấy cạnh vừa bị loại bỏ đóng vai trò quan trọng trong quá trình suy luận.

Gate trên từng message Để thực hiện việc này, GraphMask đặt một biến nhị phân (gate) lên mỗi message được truyền qua cạnh trong quá trình message passing.

Xét một cạnh:

$$e_{i,j} = (i, r, j)$$

ở lớp GNN thứ l .

Sau khi encoder sinh ra message:

$$m_{r,i}^{(l)}$$

GraphMask quyết định có giữ message này hay không thông qua một gate:

$$z_{i,j,r}^{(l)} = I_{>0.5} \left(\sigma \left(W_{g,r}^{(l)} (m_{r,i}^{(l)} \| m_{r,j}^{(l)}) \right) \right)$$

Trong đó:

- $z = 1$: giữ nguyên message;
- $z = 0$: loại bỏ message.

Ban đầu, tất cả các gate đều được khởi tạo ở trạng thái gần mở bằng cách thêm một bias dương trước hàm sigmoid. Điều này giúp GraphMask bắt đầu từ hành vi gần giống TxGNN gốc rồi mới dần học cách loại bỏ các message dư thừa.

Thay thế message Khi một gate đóng:

$$z = 0$$

message không bị đặt bằng vector 0.

Thay vào đó, GraphMask thay thế message bằng một vector nền có thể học:

$$\hat{m}_{i,r}^{(l)} = z_{i,j,r}^{(l)} m_{i,r}^{(l)} + (1 - z_{i,j,r}^{(l)}) b_r^{(l)}$$

Việc sử dụng baseline vector giúp mô hình vẫn hoạt động ổn định trong quá trình đánh giá mức độ quan trọng của từng cạnh.

Huấn luyện GraphMask Trong suốt quá trình huấn luyện GraphMask, encoder và decoder của TxGNN không được cập nhật.

Chỉ các tham số của mạng tạo gate:

$$W_g$$

được tối ưu.

GraphMask học theo hai mục tiêu đồng thời:

1. duy trì dự đoán sau khi loại bỏ các message gần giống với dự đoán ban đầu của TxGNN (*faithfulness*);
2. loại bỏ nhiều message nhất có thể để lời giải thích ngắn gọn và dễ diễn giải (*sparsity*).

Kết quả Sau khi huấn luyện, GraphMask có thể xác định tập nhỏ các cạnh mà việc loại bỏ chúng sẽ làm thay đổi đáng kể dự đoán của TxGNN.

Các cạnh còn lại được xem là những bằng chứng quan trọng nhất và có thể ghép lại thành các chuỗi suy luận nhiều bước (*multi-hop reasoning paths*) giải thích tại sao mô hình dự đoán một thuốc có khả năng điều trị hoặc chống chỉ định đối với một bệnh.

4 Evaluation

4.1 Evaluation of TxGNN for drug repurposing

4.1.1 Dataset split and evaluation settings

Để đánh giá khả năng tổng quát hóa, nhóm tác giả xây dựng các tập *holdout diseases* bằng cách lựa chọn một nhóm bệnh từ medical knowledge graph (KG) và loại bỏ hoàn toàn các thông tin liên quan đến các bệnh này trong giai đoạn huấn luyện.

Các bệnh trong tập holdout sau đó được sử dụng để đánh giá khả năng của mô hình trong việc chuyển giao kiến thức đã học sang các bệnh chưa từng được quan sát.

Hai chiến lược xây dựng tập holdout được sử dụng:

- **Random holdout:**

Training: $Drug_A \rightarrow Disease_X$
 $Drug_D \rightarrow Disease_Y$
Test: $Drug_B \rightarrow Disease_X$
 $Drug_C \rightarrow Disease_X$

- **Zero-shot holdout:**

Training: $Drug_A \rightarrow Disease_X$
 $Drug_B \rightarrow Disease_X$
Test: $Drug_C \rightarrow Disease_Y$
 $Drug_D \rightarrow Disease_Y$

mô hình chưa từng quan sát $Disease_Y$ hoặc các thuốc điều trị bệnh này trong quá trình huấn luyện, do đó phải dựa vào các mối quan hệ sinh học trong KG để suy luận.

TxGNN được so sánh với tám phương pháp đối chứng thuộc nhiều nhóm khác nhau:

1. **Network medicine-based methods:** các phương pháp dựa trên sự tương đồng về phân bố mạng hoặc xác suất xuất hiện của các thực thể trong mạng sinh học.
 - Kullback–Leibler divergence (KL): đo độ khác biệt giữa hai phân phối xác suất, được sử dụng để đánh giá mức độ tương đồng giữa biểu diễn mạng của thuốc và bệnh.
 - Jensen–Shannon divergence (JS): phiên bản đối xứng và ổn định hơn của KL divergence, dùng để đo khoảng cách giữa hai phân phối xác suất.
2. **Graph topology-based methods:** khai thác cấu trúc liên kết của mạng sinh học để đánh giá mức độ gần nhau giữa thuốc và bệnh.
 - Network proximity: đo khoảng cách hoặc mức độ lân cận giữa nút thuốc và nút bệnh trong mạng.
 - Diffusion State Distance (DSD): đánh giá sự tương đồng giữa các nút dựa trên quá trình lan truyền thông tin trong mạng.
3. **Graph neural network methods:** các mô hình học biểu diễn trực tiếp từ đồ thị dị thể bằng cơ chế message passing.
 - Relational Graph Convolutional Network (RGCN): mở rộng GCN để xử lý nhiều loại quan hệ trong đồ thị.

- Heterogeneous Graph Transformer (HGT): sử dụng kiến trúc Transformer để học biểu diễn trên đồ thị dị thể với nhiều loại nút và cạnh.
 - Heterogeneous Attention Network (HAN): sử dụng attention trên các meta-path để học thông tin từ các loại quan hệ khác nhau trong đồ thị.
4. **Biomedical language model:** mô hình ngôn ngữ được huấn luyện trên dữ liệu y sinh, khai thác thông tin ngữ nghĩa từ văn bản.
- BioBERT: mô hình BERT được fine-tune trên các corpus y sinh, dùng để học biểu diễn ngữ nghĩa của các khái niệm và mối quan hệ y khoa.

4.1.2 Traditional drug–disease prediction benchmark

các cặp thuốc–bệnh (*drug–disease pairs*) được chia ngẫu nhiên thành tập huấn luyện và tập kiểm tra.

Do chỉ một phần cạnh trong KG bị loại bỏ, các bệnh trong tập kiểm tra vẫn xuất hiện trong quá trình huấn luyện. Vì vậy, mô hình đã quan sát một số quan hệ giữa các thuốc khác và cùng một bệnh trong giai đoạn training. Nhiệm vụ đánh giá lúc này chủ yếu kiểm tra khả năng mở rộng danh sách các ứng viên thuốc cho những bệnh đã có một phần thông tin điều trị.

Hiệu suất được đánh giá bằng:

AUPRC

(*Area Under the Precision–Recall Curve*), trong đó:

- **Precision** đo tỷ lệ các thuốc được dự đoán là đúng trong tổng số thuốc mà mô hình lựa chọn;
- **Recall** đo khả năng tìm ra các thuốc thực sự phù hợp trong toàn bộ các thuốc có khả năng điều trị.

Trong thiết lập này, ba phương pháp đạt:

$$\text{AUPRC} > 0.80$$

với HAN đạt hiệu suất cao nhất:

$$\text{AUPRC}_{HAN} = 0.873$$

Trong nhiệm vụ dự đoán chỉ định thuốc (*drug indication prediction*), TxGNN đạt:

$$\text{AUPRC}_{TxGNN} = 0.913$$

cao hơn HAN:

+4.3%

Tuy nhiên, benchmark truyền thống có thể đánh giá quá cao khả năng suy luận của mô hình do hiện tượng *shortcut learning*. Cụ thể, khi một bệnh đã xuất hiện trong quá trình huấn luyện, mô hình có thể dự đoán một thuốc mới dựa trên sự tương đồng giữa các thuốc đã biết thay vì thực sự suy luận từ các cơ chế sinh học liên quan đến bệnh.

Do đó, thiết lập này chưa phản ánh đầy đủ bài toán *zero-shot drug repurposing*, trong đó mô hình cần dự đoán thuốc cho các bệnh chưa từng được quan sát trong quá trình huấn luyện.

4.1.3 Zero-shot drug repurposing evaluation

Để đánh giá khả năng suy luận trên bệnh mới, paper xây dựng thiết lập zero-shot nghiêm ngặt hơn.

Các bệnh trong tập kiểm tra:

- chưa từng xuất hiện trong tập huấn luyện;
- không có quan hệ drug-disease indication hoặc contraindication được quan sát trong training KG.

Vì vậy, mô hình không thể dựa vào:

- drug similarity;
- chỉ định thuốc đã biết.

Thay vào đó, TxGNN phải khai thác các mối liên hệ sinh học trong KG:

[Drug $\rightarrow$ Protein $\rightarrow$ Gene $\rightarrow$ Disease]

để suy luận ứng viên điều trị.

Trong thiết lập này, TxGNN vượt trội toàn bộ các phương pháp đối chứng.

So với phương pháp tốt thứ hai:

- **Drug indication prediction:**

TxGNN đạt:

$$\text{AUPRC} = 0.482$$

cao hơn phương pháp tốt thứ hai (HAN, AUPRC = 0.405).

- **Drug contraindication prediction:**

TxGNN đạt:

$$\text{AUPRC} = 0.399$$

cao hơn phương pháp tốt thứ hai (RGCN, AUPRC = 0.322)

4.1.4 Evaluation across disease areas

Để đánh giá khả năng tổng quát hóa trên các nhóm bệnh khác nhau, tác giả xây dựng chín tập *holdout* theo từng *disease area*, bao gồm:

- Diabetes;
- Adrenal gland diseases;
- Autoimmune diseases;
- Anemia;
- Neurodegenerative diseases;
- Mental health disorders;
- Metabolic disorders;
- Cardiovascular diseases;
- Cancer.

Mỗi tập kiểm tra được xây dựng theo thiết lập zero-shot với các bệnh thỏa đồng thời ba điều kiện:

- không có thuốc được phê duyệt xuất hiện trong tập huấn luyện;
- có mức độ tương đồng thấp với các bệnh trong tập huấn luyện;
- bị loại bỏ các thực thể sinh học lân cận nhằm hạn chế thông tin phân tử có thể hỗ trợ suy luận.

Kết quả cho thấy TxGNN đạt hiệu suất cao trên cả chín nhóm bệnh. Ở từng nhóm bệnh riêng lẻ, một số phương pháp cơ sở vẫn đạt kết quả tốt. Cụ thể, BioBERT đạt hiệu suất cao nhất trong 7/9 nhóm đối với bài toán *drug indication*, trong khi RGCN đạt kết quả tốt nhất ở 8/9 nhóm đối với bài toán *drug contraindication*. Tuy nhiên, TxGNN là mô hình duy nhất duy trì hiệu suất cạnh tranh hoặc vượt trội trên toàn bộ chín nhóm bệnh, cho thấy khả năng tổng quát hóa ổn định trên nhiều lĩnh vực bệnh lý khác nhau.




Figure 3:

4.1.5 Evaluation of TxGNN Explainer

đánh giá khả năng giải thích của TxGNN thông qua các đường suy luận nhiều bước trên đồ thị tri thức (*multi-hop interpretable paths*) dưới dạng:

$$Drug \rightarrow Concept_1 \rightarrow Concept_2 \rightarrow Disease$$

Đối với mỗi dự đoán, TxGNN Explainer trích xuất một đồ thị con thưa (*sparse interpretable subgraph*) chỉ gồm các cạnh quan trọng nhằm giải thích quyết định của mô hình.

Mỗi cạnh e trong đồ thị được gán một điểm quan trọng (*importance score*):

$$\text{importance}(e) \in [0, 1].$$

Các cạnh có:

$$\text{importance}(e) > 0.5$$

được xem là những cạnh đóng góp đáng kể vào dự đoán.

Khi chỉ giữ lại các cạnh quan trọng, chỉ còn khoảng:

$$14.9\%$$

tổng số cạnh của đồ thị tri thức, nhưng hiệu suất của mô hình chỉ giảm rất nhẹ:

$$\text{AUPRC} : 0.890 \rightarrow 0.886.$$

Điều này cho thấy phần lớn thông tin cần thiết cho dự đoán được tập trung trong một tập nhỏ các cạnh quan trọng.

Ngược lại, khi loại bỏ các cạnh quan trọng và chỉ giữ các cạnh có:

$$\text{importance}(e) < 0.5,$$

hiệu suất giảm đáng kể:

$$\text{AUPRC} : 0.890 \rightarrow 0.628.$$

Ngoài ra, tác giả đánh giá chất lượng của các giải thích thông qua ba tiêu chí:

- **Insertion:** đo khả năng duy trì kết quả dự đoán khi chỉ giữ lại và bổ sung dần các cạnh quan trọng;
- **Deletion:** đo mức suy giảm hiệu suất khi lần lượt loại bỏ các cạnh quan trọng khỏi đồ thị;
- **Stability:** đánh giá mức độ ổn định của các đường dẫn giải thích khi đồ thị tri thức bị nhiễu hoặc có những thay đổi nhỏ.

Kết quả thực nghiệm cho thấy TxGNN Explainer tạo ra các giải thích có độ ổn định cao hơn so với các phương pháp giải thích phổ biến, bao gồm:

- GNNExplainer;
- Integrated Gradients (IG);
- Information Bottleneck (IB).

4.1.6 Human-centric evaluation of TxGNN explanations

Bên cạnh việc đánh giá độ chính xác của mô hình và chất lượng của các giải thích, tác giả tiến hành một nghiên cứu người dùng nhằm đánh giá mức độ hữu ích của các đường dẫn giải thích nhiều bước (*multi-hop interpretable paths*) trong quá trình ra quyết định của các chuyên gia.

Nghiên cứu có sự tham gia của 12 chuyên gia, bao gồm:

- 5 bác sĩ lâm sàng (*clinicians*);
- 5 nhà nghiên cứu lâm sàng (*clinical researchers*);
- 2 dược sĩ (*pharmacists*).

Trong đó có 7 nam, 5 nữ với độ tuổi trung bình là 34.3 tuổi.

Mỗi chuyên gia được yêu cầu đánh giá 16 dự đoán *drug-disease indication* do TxGNN đưa ra, trong đó có 12 dự đoán đúng và 4 dự đoán sai. Đối với mỗi dự đoán, nhóm tác giả ghi nhận ba chỉ số:

- độ chính xác đánh giá (*assessment accuracy*);
- thời gian phân tích (*exploration time*);
- mức độ tự tin (*confidence score*).

Tổng cộng có:

$$16 \times 12 = 192$$

lượt đánh giá. Mỗi người tham gia mất trung bình khoảng 65 phút để hoàn thành nghiên cứu, bao gồm đánh giá các dự đoán của TxGNN, trả lời bảng câu hỏi về khả năng sử dụng và tham gia phỏng vấn bán cấu trúc.

Kết quả cho thấy việc cung cấp các giải thích từ TxGNN Explainer giúp chuyên gia đánh giá các ứng viên tái định vị thuốc hiệu quả hơn.

Cụ thể:

- độ chính xác đánh giá tăng từ 0.542 lên 0.792 (+46%, $P = 0.0443$);
- mức độ tự tin tăng từ 2.375 lên 3.542 (+49%, $P = 0.0041$);
- thời gian phân tích tăng từ 18.36 s lên 58.31 s ($P = 0.0014$) $\rightarrow$ thời gian tăng là bằng chứng cho thấy chuyên gia thực sự sử dụng explanation để phân tích

Trong khảo sát sau nghiên cứu:

$$\frac{11}{12} = 91.6\%$$

chuyên gia đồng ý hoặc hoàn toàn đồng ý rằng các dự đoán kèm theo giải thích của TxGNN có giá trị trong quá trình đánh giá ứng viên thuốc.

Ngược lại, khi chỉ cung cấp kết quả dự đoán mà không có giải thích:

$$\frac{8}{12} = 75.0\%$$

chuyên gia không đồng ý hoặc hoàn toàn không đồng ý với việc chỉ dựa vào các dự đoán của mô hình.

Ngoài ra, mức độ tin tưởng đối với các dự đoán đúng tăng đáng kể khi sử dụng TxGNN Explainer:

$$t(11) = 3.64, \quad P < 0.01.$$

Các chuyên gia cũng cho biết các đường dẫn giải thích nhiều bước đặc biệt hữu ích trong việc:

- kiểm tra mối liên hệ giữa thuốc và các mục tiêu phân tử (*molecular targets*);
- đánh giá nguy cơ xuất hiện các tác dụng phụ tiềm ẩn;
- hiểu cơ chế sinh học đứng sau các dự đoán của mô hình.

4.1.7 Alignment with medical evidence

Bên cạnh đánh giá định lượng và nghiên cứu người dùng, tác giả tiếp tục kiểm tra mức độ phù hợp giữa các dự đoán của TxGNN, các đường dẫn giải thích và bằng chứng y khoa hiện có thông qua ba bệnh hiếm.

Quy trình đánh giá gồm ba bước:

1. **TxGNN Predictor:** dự đoán các ứng viên tái định vị thuốc, đồng thời cung cấp điểm dự đoán và thứ hạng của từng thuốc.
2. **TxGNN Explainer:** sinh các đường suy luận nhiều bước trên đồ thị tri thức, ví dụ:

$$\text{Drug} \rightarrow \text{Concept}_1 \rightarrow \text{Concept}_2 \rightarrow \text{Disease}$$

nhằm giải thích lý do lựa chọn thuốc.

3. **Medical validation:** đối chiếu các dự đoán và đường dẫn giải thích với các bằng chứng y khoa độc lập trong tài liệu nghiên cứu.

Ba trường hợp điển hình được phân tích như sau:

Case study 1: Kleefstra syndrome – Zolpidem TxGNN dự đoán *zolpidem* là ứng viên tái định vị hàng đầu cho Kleefstra syndrome, mặc dù đây là thuốc an thần tác động lên thụ thể GABA-A.

TxGNN Explainer xác định đường dẫn liên quan đến *GABRG2* và các cơ chế thần kinh, phù hợp với các báo cáo lâm sàng về hiệu ứng kích thích thần kinh nghịch lý của zolpidem, giúp cải thiện khả năng nói, vận động và mức độ tỉnh táo ở một số bệnh nhân.

Case study 2: Ehlers–Danlos syndrome – Tretinoin TxGNN dự đoán *tretinoin* là ứng viên hàng đầu và giải thích thông qua các mối liên hệ giữa *ALB*, *ALDH1A2* và quá trình tổng hợp collagen.

Giải thích này phù hợp với hiểu biết hiện nay rằng tretinoin có thể kích thích sản xuất collagen, giảm viêm và hỗ trợ phục hồi mô liên kết.

Case study 3: NSIAD – Amyl nitrite TxGNN xác định *amyl nitrite* là một trong các ứng viên tiềm năng thông qua đường dẫn:

$$\text{NSIAD} \rightarrow \text{AVPR2} \rightarrow \text{NPR1} \rightarrow \text{Amyl nitrite}$$

Đường dẫn này phản ánh vai trò của *AVPR2* trong điều hòa cân bằng nước và của *NPR1* trong điều hòa huyết áp cũng như bài tiết nước, cho thấy cơ chế dự đoán của TxGNN phù hợp với hiểu biết sinh học hiện có.

Nhìn chung, các kết quả cho thấy TxGNN không chỉ dự đoán được các ứng viên tái định vị thuốc tiềm năng mà còn cung cấp các đường dẫn giải thích có ý nghĩa sinh học, phù hợp với bằng chứng y khoa và hỗ trợ việc diễn giải kết quả dự đoán.

4.2 Limitation

- Phụ thuộc vào chất lượng của medical knowledge graph
- Dữ liệu có thể thiên lệch hoặc lỗi thời
- Chưa đánh giá độ không chắc chắn của dự đoán: ước lượng độ tin cậy của từng dự đoán.
- Chưa cá nhân hóa theo từng bệnh nhân: thông tin bệnh nhân, hồ sơ bệnh án điện tử, medical KG.
- Đánh giá trên người còn quy mô nhỏ
- Hạn chế khi đánh giá bằng EMRs: Mặc dù kết quả trên hồ sơ bệnh án điện tử rất tích cực, việc sử dụng mức độ đồng xuất hiện thuốc–bệnh (drug enrichment) vẫn có thể chịu ảnh hưởng bởi: các yếu tố gây nhiễu chưa được kiểm soát, sai lệch trong lựa chọn mẫu (selection bias).