

Guided IG: Guided Integrated Gradients: an Adaptive Path Method for Removing Noise

Le-Van Thai

August 2026

1 Overall

- Integrated Gradients (IG) có một hạn chế là thường tạo ra các giá trị gán mức độ quan trọng giả hoặc nhiễu (*spurious/noisy pixel attributions*) tại những vùng không liên quan đến lớp dự đoán khi áp dụng cho các mô hình Computer Vision. Minh chứng là trong bài Expected Gradients (EG), khi đổi nhãn mục tiêu thành một ô vuông ở góc ảnh trên bộ MNIST, IG vẫn gán giá trị quan trọng cho nhiều vùng không liên quan. Một số lý do đã được đề xuất như:
 - độ cong lớn của bề mặt đầu ra của mô hình (*output manifold*): nếu bề mặt này phẳng thì gradient thay đổi ổn định nhưng nếu nó cong mạnh thì gradient thay đổi rất nhanh khi đi trên path.
Ví dụ: Baseline — X → Ảnh thật thì giữa đường có thể đi qua vùng mà model cực kỳ nhạy, Tại điểm X, một pixel không liên quan có gradient rất lớn;
 - sai số do xấp xỉ phép tích phân bằng tổng Riemann: máy tính không tính tích phân liên tục được → Nó chia thành N bước → rồi lấy tổng → Riemann sum. Vấn đề: Nếu gradient thay đổi mượt → thì ít bước cũng OK. Nhưng nếu gradient dao động → thì các điểm lấy mẫu có thể bỏ qua những thay đổi quan trọng.
 - lựa chọn điểm tham chiếu (*baseline*).
- Tuy nhiên, hầu hết các phương pháp hiện có chỉ tập trung giảm trực tiếp lượng nhiễu trên bản đồ giải thích (*resulting attributions*) mà chưa giải quyết nguyên nhân gốc của vấn đề.
 - SmoothGrad: lấy trung bình attribution trên nhiều phiên bản của cùng một ảnh được tạo bằng cách thêm nhiễu Gaussian vào ảnh gốc.
 - XRAI: gom các attribution theo từng vùng phân đoạn để giảm ảnh hưởng của các giá trị ngoại lai.
IG: Image → Gradient từng pixel → Attribution map

XRAI: Image $\rightarrow$ Segmentation $\rightarrow$ Các vùng $\rightarrow$ Attribution từng vùng

- EG: lựa chọn baseline là một trong những nguyên nhân gây nhiễu.
 - Blur IG: thực hiện tích phân theo miền tần số, bằng cách làm mờ ảnh đầu vào trong quá trình tích phân nhằm giảm các nhiễu do biến đổi trên đường đi.
 - Manipulation Method: làm mượt đầu ra của mạng bằng cách thay thế các hàm kích hoạt ReLU bằng Softplus.
- Paper chỉ ra rằng một trong những nguyên nhân gây nhiễu là sự tích lũy nhiễu dọc theo đường tích phân (*IG path*). Khác với các phương pháp trên vốn chủ yếu giảm nhiễu bằng cách điều chỉnh đầu vào hoặc baseline, nghiên cứu này xem xét toàn bộ đường tích phân. Mỗi đường đi từ baseline đến ảnh đầu vào tương ứng với một phương pháp attribution khác nhau. Các phương pháp trước đây chủ yếu sử dụng đường thẳng (*straight path*), trong khi Blur IG sử dụng đường làm mờ (*blur path*).
 - paper giới thiệu **Adaptive Path Methods (APMs)** như một phương pháp tổng quát cho các phương pháp dựa trên đường đi (*path methods*), trong đó **Guided IG** là một trường hợp cụ thể của APM. APMs đề xuất đường tích phân được điều chỉnh dựa trên đầu vào, baseline và chính mô hình đang được giải thích.

Theo trực giác của tác giả, đường thẳng có thể đi qua những vùng có gradient bất thường, từ đó tạo ra các bản đồ attribution chứa nhiễu. Ngược lại, nếu đường tích phân được điều chỉnh theo đặc điểm của mô hình thì có thể tránh lấy mẫu tại các vùng bất thường này.

Cụ thể, Guided IG xây dựng đường đi từ baseline đến ảnh đầu vào bằng cách ưu tiên thay đổi những đặc trưng có giá trị tuyệt đối của đạo hàm riêng nhỏ nhất. Ở mỗi bước, Guided IG chọn một tập các đặc trưng có độ lớn gradient nhỏ nhất, sau đó chỉ điều chỉnh các đặc trưng này tiến gần hơn tới giá trị tương ứng trong ảnh đầu vào, trong khi giữ nguyên các đặc trưng còn lại. Khi giá trị của một đặc trưng đã bằng với giá trị trong ảnh gốc, đặc trưng đó sẽ không còn được chọn ở các bước tiếp theo. Nhờ cách xây dựng này, các bản đồ attribution thu được có mức nhiễu thấp hơn đáng kể.

2 Contributions

- Đề xuất Adaptive Path Methods (APMs), một sự tổng quát hóa của các phương pháp path-based, trong đó đường tích phân được xác định dựa trên cả mô hình và dữ liệu đầu vào.
- Giới thiệu Guided IG, một phương pháp attribution cụ thể thuộc nhóm APM, đồng thời phân tích các tính chất lý thuyết của phương pháp.

- Thực hiện các thí nghiệm chứng minh rằng Guided IG vượt trội hơn các phương pháp attribution hiện có về mặt định lượng và tạo ra các bản đồ giải thích với mức nhiễu thấp hơn.

3 Ảnh hưởng của Gradient lớn lên Attribution của IG

cách các gradient có mức độ tương quan cao (highly-correlated gradients) có thể tạo ra nhiễu trong các attribution của IG và chỉ ra cách các đường đi không phụ thuộc vào mô hình (model-agnostic paths), ví dụ như đường thẳng, có thể góp phần gây ra vấn đề này.

3.1 IG

Đối với các mô hình thị giác, với một ảnh đầu vào x , IG tính toán giá trị attribution cho từng pixel (feature) i bằng cách tích phân gradient của đầu ra mô hình F theo pixel i , như trong Công thức 1:

$$IG_i(x) = \int_0^1 \frac{\partial F(\gamma(\alpha))}{\partial \gamma_i(\alpha)} \frac{\partial \gamma_i(\alpha)}{\partial \alpha} d\alpha. \quad (1)$$

Trong đó:

- $\frac{\partial F(x)}{\partial x_i}$ là gradient của hàm F theo đặc trưng (pixel) thứ i .
- $\gamma(\alpha)$ biểu diễn các ảnh nằm trên một đường tích phân (*integral path*), với $\alpha \in [0, 1]$.

$\gamma(\alpha)$ là một hàm thay đổi cường độ pixel từ:

- ảnh *baseline*: $\gamma(0)$ (ví dụ: ảnh đen, ảnh trắng hoặc ảnh nhiễu ngẫu nhiên);
- đến ảnh đầu vào cần giải thích: $\gamma(1) = x$.

Nói cách khác, IG xây dựng một đường đi từ ảnh *baseline* đến ảnh đầu vào, sau đó tích lũy gradient dọc theo đường đi này để xác định mức độ quan trọng của từng pixel đối với dự đoán của mô hình.

3.2 Nguồn gốc nhiễu đến từ các đường đi không phụ thuộc vào mô hình

Các nghiên cứu trước đây cho rằng nhiễu trong IG có thể xuất phát từ nhiều nguyên nhân khác nhau, bao gồm:

- việc lựa chọn điểm tham chiếu (*baseline*);
- sự tích lũy gradient trong các vùng bão hòa (*saturated regions*);
- hình dạng của bề mặt hàm số của mô hình (*model surface*).

3.3 Gradient theo từng pixel lớn hơn nhiều so với gradient theo hướng đường đi

Để phân tích nguồn gốc của nhiễu, tác giả so sánh hai đại lượng:

- chuẩn L_2 của gradient $\|\nabla F(x)\|_2$, phản ánh độ lớn của các đạo hàm riêng theo từng pixel;
- đạo hàm có hướng (*directional derivative*), phản ánh tốc độ thay đổi của đầu ra theo đúng hướng di chuyển của đường tích phân.

Ví dụ, giả sử ảnh đầu vào chỉ gồm ba pixel:

$$x = (x_1, x_2, x_3),$$

khi đó gradient của mô hình là

$$\nabla F(x) = \left(\frac{\partial F}{\partial x_1}, \frac{\partial F}{\partial x_2}, \frac{\partial F}{\partial x_3} \right).$$

Giả sử

$$\nabla F(x) = (0.2, 4, 5).$$


Điều này có nghĩa là nếu thay đổi riêng từng pixel thì đầu ra của mô hình nhạy nhất với pixel thứ hai và thứ ba.

Tuy nhiên, IG không thay đổi từng pixel độc lập mà di chuyển đồng thời tất cả các pixel theo một đường tích phân từ baseline đến ảnh đầu vào. Do đó, đại lượng quan trọng không phải là độ lớn của gradient mà là đạo hàm có hướng:

$$\nabla F(x) \cdot \frac{d\gamma(\alpha)}{d\alpha},$$

tức là tích vô hướng giữa gradient và hướng di chuyển của đường tích phân.

Nếu gradient có độ lớn rất lớn nhưng chủ yếu hướng sang các chiều khác với hướng của đường tích phân, thì đạo hàm có hướng vẫn rất nhỏ. Nói cách khác, mô hình rất nhạy khi thay đổi theo một số hướng trong không gian đầu vào, nhưng gần như không thay đổi theo đúng hướng mà IG đang tích phân.



Hình 1: So sánh giữa đạo hàm có hướng và độ lớn gradient. Trong Hình 3b, sau khoảng $0.3 < \alpha < 1$, đạo hàm có hướng gần bằng 0, cho thấy đầu ra của mô hình hầu như không còn thay đổi khi tiếp tục di chuyển trên đường tích phân. Tuy nhiên, Hình 3c cho thấy độ lớn gradient vẫn rất lớn. Điều này chứng tỏ gradient chủ yếu hướng sang các chiều khác với hướng của đường tích phân, khiến các pixel không liên quan vẫn có thể tạo ra các attribution lớn.

Ví dụ trực giác. Có thể hình dung gradient giống như **lực gió** tác động theo mọi hướng, còn đạo hàm có hướng (*directional derivative*) chỉ đo phần lực thực sự đẩy ta theo hướng đang di chuyển.

Giả sử bạn muốn đi từ **Nam** ra **Bắc**. Hướng bạn đang đi là

↑

nhưng gió lại thổi rất mạnh theo hướng Đông

→→→

Khi đó:

- Gradient norm rất lớn vì lực gió rất mạnh.
- Tuy nhiên, directional derivative lại rất nhỏ vì phần lực theo hướng Bắc gần như bằng 0.


Điều này cho thấy mặc dù mô hình rất nhạy nếu di chuyển sang các hướng khác trong không gian đầu vào, nhưng đầu ra của mô hình gần như không thay đổi theo đúng hướng mà IG đang tích phân.

Theo paper, đây chính là nguyên nhân khiến các gradient của những pixel không liên quan vẫn có thể có độ lớn rất lớn và tích lũy dọc theo đường tích phân, từ đó tạo ra các attribution nhiều.

3.4 Gradient không phải lúc nào cũng triệt tiêu nhau

Một giả thuyết tự nhiên là các gradient gây nhiễu sẽ tự triệt tiêu trong quá trình tích phân. Lý do là nếu tại các điểm khác nhau trên đường tích phân, gradient chỉ theo nhiều hướng khác nhau thì khi cộng toàn bộ các gradient lại, tổng của chúng sẽ gần bằng 0.

Tuy nhiên, paper chỉ ra rằng điều này không phải lúc nào cũng đúng. Nguyên nhân là đường tích phân có thể đi qua những vùng mà bề mặt của mô hình thay đổi rất mạnh, khiến gradient tại đó có độ lớn rất lớn. Mặc dù các vùng này không trực tiếp quyết định đầu ra của mô hình, chúng vẫn tạo ra các gradient đủ lớn để ảnh hưởng đến kết quả tích phân.



Hình 2: Đường IG đi từ baseline (A) đến ảnh đầu vào (E) và đi qua điểm B. Mặc dù hai điểm C và D không nằm trên đường tích phân, chúng lại có giá trị dự đoán rất khác nhau và nằm rất gần B. Điều này làm cho vùng lân cận B có gradient rất lớn. Vì đường IG đi qua B nên quá trình tích phân vẫn thu thập các gradient này, khiến các pixel không liên quan cũng có thể nhận attribution khác 0.

3.5 Đường tích phân thẳng là nguyên nhân chính

Trong IG, đường tích phân là một đường thẳng nối từ baseline đến ảnh đầu vào. Đường đi này chỉ phụ thuộc vào baseline và ảnh đầu vào mà hoàn toàn không xét đến đặc điểm của mô hình.

Do đó, đường tích phân có thể đi qua các vùng mà:

- gradient của mô hình có độ lớn rất lớn;
- nhưng hướng của gradient lại không cùng hướng với hướng di chuyển của đường tích phân.

Để đánh giá điều này, tác giả sử dụng độ tương đồng cosine (*cosine similarity*) giữa:

- gradient của mô hình $\nabla F(x)$;
- và hướng di chuyển trên đường tích phân $\frac{d\gamma(\alpha)}{d\alpha}$.

Nếu cosine similarity gần bằng 0, điều đó cho thấy gradient chủ yếu hướng sang các chiều khác với hướng di chuyển của đường tích phân. Mặc dù đầu ra của mô hình gần như không thay đổi theo hướng IG đang đi, đường tích phân vẫn đi qua các vùng có gradient rất lớn. Do đó, các gradient của những pixel không liên quan vẫn có thể tích lũy trong quá trình tích phân và tạo ra các attribution nhiễu.

Ví dụ, giả sử đường IG di chuyển theo hướng:

↓

trong khi gradient của mô hình chủ yếu hướng sang bên phải:

→→→→

Hai hướng này gần như vuông góc với nhau. Điều đó cho thấy mô hình rất nhạy nếu di chuyển sang bên phải, nhưng gần như không thay đổi theo hướng mà IG đang đi. Tuy nhiên, vì đường tích phân vẫn đi qua vùng có gradient rất lớn nên các thành phần gradient của những pixel không liên quan vẫn có thể được tích lũy, dẫn đến attribution cao ở các vùng không liên quan.

3.6 Tóm lại

Vấn đề của IG không chỉ nằm ở việc lựa chọn baseline hay sai số khi xấp xỉ tích phân. Theo paper, nguyên nhân sâu hơn là:

- IG sử dụng một đường tích phân cố định.
- Đường đi này không phụ thuộc vào mô hình đang được giải thích.
- Đường tích phân có thể đi qua các vùng trên bề mặt của mô hình có gradient rất lớn.
- Gradient của các pixel không liên quan có thể tương quan và tích lũy dọc theo đường tích phân.
- Kết quả là các nhiễu được cộng dồn trong quá trình tích phân, làm xuất hiện các attribution sai.

Đây cũng chính là động lực để Guided IG đề xuất sử dụng một đường tích phân thích nghi với mô hình, thay vì luôn sử dụng đường thẳng từ baseline đến ảnh đầu vào.

4 Adaptive Paths và Guided IG

Để khắc phục hạn chế của IG, paper đề xuất **Adaptive Path Methods (APMs)**, một sự tổng quát hóa của các phương pháp dựa trên đường đi (*Path Methods - PMs*).

Ý tưởng chính của APM là thay vì sử dụng một đường tích phân cố định chỉ phụ thuộc vào *baseline* và ảnh đầu vào, đường tích phân được phép phụ thuộc vào chính mô hình cần giải thích. Do đó, APM là một tập mở rộng (*superset*) của các Path Methods truyền thống.

4.1 Định nghĩa

Cho một mô hình

$$F : R^N \rightarrow R,$$

với đầu vào

$$X = \{x_1, \dots, x_N\}.$$

Gọi

$$X_B = \{x_1^B, \dots, x_N^B\}$$

là ảnh baseline và

$$X_I = \{x_1^I, \dots, x_N^I\}$$

là ảnh đầu vào cần giải thích.

Thay vì sử dụng một đường tích phân cố định, APM xây dựng một đường đi

$$\gamma^F = (\gamma_1^F, \dots, \gamma_N^F),$$

trong đó đường đi phụ thuộc vào chính mô hình F và thỏa mãn

$$\gamma_i^F(0) = x_i^B, \quad \gamma_i^F(1) = x_i^I,$$

với mọi đặc trưng i .

Khi đó, attribution của đặc trưng x_i theo đường tích phân γ^F được xác định bởi

$$a_i^{\gamma^F}(X_I) = \int_0^1 \frac{\partial F(\gamma^F(\alpha))}{\partial \gamma_i^F(\alpha)} \frac{\partial \gamma_i^F(\alpha)}{\partial \alpha} d\alpha.$$

Có thể thấy công thức trên gần giống với Integrated Gradients. Điểm khác biệt duy nhất là đường tích phân γ không còn cố định mà được phép phụ thuộc vào mô hình đang được giải thích.

Trong các Path Methods truyền thống như IG, đường tích phân $\gamma(\alpha)$ được xác định hoàn toàn bởi baseline và ảnh đầu vào:

$$\gamma(\alpha) = X_B + \alpha(X_I - X_B).$$

Do đó, cùng một cặp (X_B, X_I) sẽ luôn tạo ra cùng một đường đi, bất kể mô hình được giải thích là gì.

Ngược lại, Adaptive Path Methods cho phép đường tích phân phụ thuộc vào mô hình F , được ký hiệu là $\gamma^F(\alpha)$. Khi đó, hai mô hình khác nhau có thể tạo ra hai đường tích phân khác nhau:

$$\gamma^{F_1}(\alpha) \neq \gamma^{F_2}(\alpha).$$

Nhờ vậy, đường đi có thể được điều chỉnh để tránh các vùng trên bề mặt mô hình có gradient bất thường.

Giống như các Path Methods truyền thống, Adaptive Path Methods vẫn thỏa mãn ba tiên đề quan trọng:

- **Implementation Invariance;**
- **Sensitivity;**
- **Completeness.**

4.2 Các đặc tính mong muốn

Như đã phân tích, một trong những nguyên nhân chính gây ra attribution nhiễu trong IG là đường tích phân có thể đi qua các vùng trong không gian đầu vào có gradient lớn, mặc dù các vùng này không thực sự đóng góp vào dự đoán của mô hình.

Trong IG, attribution của một đặc trưng được tính bằng cách tích lũy các gradient dọc theo đường đi:

$$IG_i(X_I) = \int_0^1 \frac{\partial F(\gamma(\alpha))}{\partial \gamma_i(\alpha)} \frac{\partial \gamma_i(\alpha)}{\partial \alpha} d\alpha.$$

Do đó, nếu đường tích phân đi qua các vùng có gradient lớn nhưng không liên quan đến đặc trưng cần giải thích, các thành phần gradient này vẫn được tích lũy và tạo ra attribution sai.

Vì vậy, tác giả mong muốn tìm một đường tích phân có khả năng tránh các vùng gây ra sự tích lũy gradient không cần thiết. Gọi lượng nhiễu tích lũy trên một đường đi là L_{noise} . Đại lượng này được xây dựng dựa trên chính thành phần đóng góp của IG, bằng cách đo tổng độ lớn của các gradient được tích lũy trên toàn bộ đặc trưng và toàn bộ đường đi:

$$L_{\text{noise}} = \sum_{i=1}^N \int_0^1 \left| \frac{\partial F(\gamma^F(\alpha))}{\partial \gamma_i^F(\alpha)} \frac{\partial \gamma_i^F(\alpha)}{\partial \alpha} \right| d\alpha.$$

Dấu giá trị tuyệt đối được sử dụng để tránh hiện tượng các gradient trái dấu triệt tiêu nhau trong quá trình tích phân. Khi đó, L_{noise} đại diện cho tổng lượng gradient mà đường đi thu thập được, bất kể hướng của gradient là tăng hay giảm.

Bài toán tìm đường tích phân tối ưu có thể được viết như:

$$\gamma^{F*} = \arg \min_{\gamma^F \in \Gamma} L_{\text{noise}}.$$

Ý tưởng là nếu giảm được L_{noise} , đường tích phân sẽ hạn chế đi qua các vùng có gradient lớn nhưng không đóng góp thực sự vào đầu ra của mô hình, từ đó giảm các attribution nhiễu.

Tuy nhiên, việc tối ưu trực tiếp bài toán này yêu cầu biết toàn bộ bề mặt dự đoán của mạng nơ-ron trong không gian đầu vào. Đây là điều gần như không khả thi do số chiều của không gian ảnh rất lớn.

Vì vậy, thay vì giải bài toán tối ưu toàn cục, tác giả đề xuất một phương pháp xấp xỉ tham lam (*greedy approximation*) mang tên **Guided Integrated Gradients**. Phương pháp này xây dựng đường đi từng bước bằng cách ưu tiên thay đổi các đặc trưng ít gây ảnh hưởng đến gradient của mô hình.

4.3 Guided IG

Guided IG là một trường hợp cụ thể của Adaptive Path Methods.

Tương tự IG, đường tích phân của Guided IG bắt đầu từ baseline và kết thúc tại ảnh đầu vào cần giải thích. Tuy nhiên, thay vì thay đổi tất cả các pixel đồng thời theo một đường thẳng, Guided IG xây dựng đường đi một cách thích nghi dựa trên gradient của mô hình.

Cụ thể, tại mỗi bước, Guided IG thực hiện các bước sau:

- Xác định tập S gồm các pixel có giá trị tuyệt đối của gradient nhỏ nhất (ví dụ: 10% pixel có gradient nhỏ nhất).
- Chỉ xét các pixel chưa đạt tới giá trị tương ứng trong ảnh đầu vào.
- Cập nhật các pixel thuộc tập S tiến gần hơn đến giá trị trong ảnh đầu vào.
- Giữ nguyên các pixel còn lại trong bước hiện tại.

Quá trình này tiếp tục cho đến khi tất cả các pixel đạt giá trị tương ứng với ảnh đầu vào.

Nói cách khác, Guided IG không thay đổi toàn bộ ảnh cùng lúc như IG, mà ưu tiên thay đổi những pixel mà mô hình ít nhạy cảm nhất tại thời điểm hiện tại. Điều này giúp đường tích phân tránh đi qua các vùng có gradient lớn nhưng không cần thiết.

4.4 Độ dài đường đi của Guided IG

Do Guided IG chỉ cập nhật một phần các pixel tại mỗi bước, đường đi của nó thường không phải là đường thẳng mà có dạng ziczac trong không gian đầu vào. Vì vậy, độ dài đường đi theo chuẩn L_2 của Guided IG có thể lớn hơn hoặc bằng đường đi thẳng của IG:

$$\|\text{GIG}\|_2 \geq \|\text{IG}\|_2.$$

Nguyên nhân là đường thẳng là đường ngắn nhất nối hai điểm trong không gian Euclid, trong khi Guided IG có thể phải đi qua nhiều hướng khác nhau để tránh các vùng gradient bất thường.

Tuy nhiên, theo chuẩn L_1 , hai đường đi có cùng tổng độ thay đổi của từng pixel:

$$\|\text{GIG}\|_1 = \|\text{IG}\|_1.$$

Điều này xảy ra vì mỗi pixel trong Guided IG chỉ thay đổi theo đúng hướng từ baseline đến ảnh đầu vào. Mỗi pixel hoặc không thay đổi trong một bước, hoặc thay đổi theo cùng một chiều cho đến khi đạt giá trị cuối cùng.

- Khoảng cách L1 giống nhau $\rightarrow$ tổng lượng thay đổi của ảnh không đổi.
- Khoảng cách L2 lớn hơn $\rightarrow$ đường đi hình học dài hơn do phải đi vòng.

Nghĩa là: Guided IG không tạo ra "đường dài hơn" vì thay đổi quá nhiều pixel. Nó chỉ:

- phân phối lại thứ tự thay đổi pixel;
- chọn pixel nào thay đổi trước;
- tránh vùng gradient lớn.

4.5 Xấp xỉ hiệu quả

Trong lý thuyết, Guided IG có thể được xây dựng bằng cách cập nhật từng pixel riêng biệt. Cụ thể, tại mỗi bước, thuật toán sẽ lựa chọn các pixel có độ lớn gradient nhỏ nhất, sau đó di chuyển các pixel này từ giá trị baseline tiến dần đến giá trị tương ứng trong ảnh đầu vào.

Tuy nhiên, với số lượng pixel rất lớn trong ảnh, cách tiếp cận này không khả thi về mặt tính toán. Mỗi bước cập nhật cần tính lại gradient của mô hình tại vị trí hiện tại trên đường đi. Do đó, nếu cập nhật từng pixel riêng biệt, số lượng bước cần thiết sẽ rất lớn.

Vì vậy, trong thực nghiệm, tác giả sử dụng một phiên bản xấp xỉ:

- tại mỗi bước chọn một nhóm pixel có độ lớn gradient nhỏ nhất (ví dụ 10% số pixel);
- đồng thời cập nhật toàn bộ nhóm pixel được chọn;
- giữ nguyên các pixel còn lại trong bước hiện tại.

Cơ chế này có thể minh họa bằng một ví dụ đơn giản. Giả sử tại một thời điểm trên đường đi, ảnh hiện tại là:

$$X^0 = (0, 0, 0, 0, 0, 0, 0, 0, 0, 0)$$

và ảnh đầu vào cần giải thích là:

$$X_I = (1, 1, 1, 1, 1, 1, 1, 1, 1, 1).$$

Ban đầu, ảnh hiện tại chính là baseline. Guided IG tính gradient của mô hình tại vị trí này. Giả sử giá trị tuyệt đối của gradient theo từng pixel là:

$$|\nabla F(X^0)| = (0.1, 5.0, 2.3, 0.2, 8.1, 1.5, 4.2, 0.05, 3.0, 6.0).$$

Các pixel có gradient nhỏ nhất là pixel thứ 8 và pixel thứ 1:

$$0.05, \quad 0.1.$$

Giả sử chọn 20% số pixel, thuật toán sẽ cập nhật hai pixel này trước. Thay vì thay đổi toàn bộ ảnh, chỉ hai pixel được tiến gần hơn tới giá trị trong ảnh đầu vào. Ví dụ, nếu mỗi bước di chuyển 10% khoảng cách còn lại:

$$x_i^{new} = x_i + 0.1(x_i^I - x_i),$$

thì:

$$X^0 = (0, 0, 0, 0, 0, 0, 0, 0, 0, 0)$$

trở thành:

$$X^1 = (0.1, 0, 0, 0, 0, 0, 0, 0.1, 0, 0).$$

Như vậy, vị trí hiện tại trên đường đi đã thay đổi:

$$X^0 \rightarrow X^1,$$

trong đó pixel thứ 1 và pixel thứ 8 đã tiến gần hơn tới ảnh đầu vào, còn các pixel khác vẫn giữ nguyên giá trị baseline.

Tại vị trí mới X^1 , gradient của mô hình được tính lại. Giả sử:

$$|\nabla F(X^1)| = (4.0, 0.3, 2.0, 5.1, 0.05, 3.5, 1.2, 2.5, 0.1, 6.0).$$

Lúc này hai pixel có gradient nhỏ nhất lại thay đổi, đó là pixel thứ 5 và pixel thứ 9. Guided IG tiếp tục cập nhật:

$$X^1 \rightarrow X^2,$$

với:

$$X^2 = (0.1, 0, 0, 0, 0.1, 0, 0, 0.1, 0.1, 0).$$

Quá trình này tiếp tục:

$$X^0 \rightarrow X^1 \rightarrow X^2 \rightarrow \dots \rightarrow X_I,$$

mỗi bước lại:

1. tính gradient tại vị trí hiện tại;
2. chọn nhóm pixel có gradient nhỏ nhất;

3. cập nhật nhóm pixel đó tiến gần hơn tới ảnh đầu vào.

Sau mỗi bước, khoảng cách L_1 giữa ảnh hiện tại và ảnh đầu vào giảm dần. Khi số bước tăng hoặc tỷ lệ pixel được cập nhật trong mỗi bước giảm xuống, đường đi thu được sẽ càng gần với Guided IG lý tưởng.

4.6 Khả năng song song hóa

Do đường đi của Guided IG được xây dựng một cách động, mỗi bước cập nhật phụ thuộc vào vị trí hiện tại trên đường đi và gradient của mô hình tại vị trí đó. Vì vậy, các bước tiếp theo không thể được tính trước hoặc thực hiện song song trong cùng một ảnh.

Ví dụ, sau khi cập nhật từ X^k đến X^{k+1} , thuật toán phải tính lại gradient tại vị trí mới:

$$\nabla F(X^{k+1})$$

để xác định nhóm pixel nào sẽ được cập nhật ở bước tiếp theo. Do đó, quá trình tạo đường đi:

$$X^0 \rightarrow X^1 \rightarrow X^2 \rightarrow \dots \rightarrow X_I$$

phải được thực hiện tuần tự.

Tuy nhiên, attribution của các ảnh khác nhau là độc lập. Vì vậy, khi cần giải thích nhiều ảnh, quá trình tính toán vẫn có thể được song song hóa bằng cách xử lý nhiều ảnh trong cùng một batch.

Nói cách khác, Guided IG không thể song song hóa theo chiều dài của một đường đi, nhưng có thể song song hóa theo số lượng ảnh cần giải thích.

5 Experiments and Results

đánh giá Guided IG bằng hai hướng tiếp cận:

- quan sát hành vi của Guided IG khi tính attribution trên một đường đi khép kín (closed path).
- Sau đó đánh giá hiệu năng của nó bằng các bộ benchmark, dataset và mô hình phổ biến.

5.1 Attribution của một đường đi khép kín

Một trong những khó khăn lớn khi đánh giá các phương pháp attribution là không tồn tại ground truth cho attribution của từng feature. Với một ảnh đầu vào X_I , chúng ta không biết chính xác:

- feature nào thực sự đóng góp vào dự đoán của mô hình;
- mức độ đóng góp chính xác của từng feature là bao nhiêu.

Do đó, cần một cách đánh giá gián tiếp dựa trên các tính chất lý thuyết của attribution method.

5.1.1 Ý tưởng dựa trên tính chất Completeness

Integrated Gradients thỏa mãn tiên đề Completeness, nghĩa là tổng attribution của tất cả feature trên một đường đi bất kỳ bằng sự thay đổi đầu ra của mô hình giữa điểm cuối và điểm đầu của đường đi:

$$\sum_i a_i = F(X_I) - F(X_B).$$

Xét trường hợp đặc biệt khi đường đi là một đường khép kín (closed path), tức là điểm bắt đầu và điểm kết thúc giống nhau.

Ví dụ:

$$A \rightarrow B \rightarrow C \rightarrow A.$$

Khi đó:

$$F(A) - F(A) = 0.$$

Theo tính chất Completeness:

$$\sum_i a_i = 0.$$

Nghĩa là tổng attribution trên một closed path phải bằng 0.

Tuy nhiên, điều này chỉ đảm bảo tổng attribution bằng 0, mà không cho biết giá trị attribution của từng feature. Ví dụ:

$$a_1 = 10, \quad a_2 = -10.$$

Khi đó:

$$a_1 + a_2 = 0,$$

nhưng không thể kết luận từng attribution riêng lẻ là đúng hay sai.

5.1.2 Xây dựng ground truth attribution

Để giải quyết vấn đề này, tác giả định nghĩa ground truth attribution dựa trên trung bình attribution của tất cả các đường đi khép kín có thể có.

Ý tưởng này tương tự với cách xây dựng Shapley value, trong đó đóng góp của một feature được xác định bằng cách xem xét tất cả các khả năng kết hợp hoặc thứ tự đóng góp khác nhau của các feature.

Xét tập tất cả các đường đi khép kín bắt đầu và kết thúc tại cùng một điểm A :

$$A \rightarrow A.$$

Với mỗi đường đi p , luôn tồn tại một đường đi ngược p' :

$$p' : A \rightarrow A$$

sao cho:

$$a_i(p) + a_i(p') = 0.$$

Ví dụ, nếu một đường đi tạo ra attribution:

$$A \rightarrow B : +a$$

thì đường đi ngược lại:

$$B \rightarrow A : -a$$

sẽ tạo ra attribution ngược dấu.

Vì mọi đường đi đều có một đường đi ngược tương ứng, khi lấy trung bình trên toàn bộ các đường đi:

$$\frac{1}{|P|} \sum_{p \in P} a_i(p) = 0.$$

Do đó, attribution trung bình của một closed path là:

$$a_i(A \rightarrow A) = 0$$

đối với mọi feature.

Đây được xem là một ground truth attribution lý tưởng cho việc đánh giá: một phương pháp attribution tốt phải trả về attribution gần bằng 0 khi đường đi bắt đầu và kết thúc tại cùng một điểm.

5.1.3 Xây dựng closed path ngẫu nhiên trong thực nghiệm

Trong thực tế, không thể tính trung bình trên toàn bộ các đường đi có thể có. Vì vậy, tác giả sử dụng một xấp xỉ bằng cách tạo các closed path ngẫu nhiên.

Một closed path được tạo như sau:

$$A \rightarrow B \rightarrow C \rightarrow A.$$

Do tính chất cộng của path integral, attribution của toàn bộ đường đi có thể phân tách thành:

$$a(A \rightarrow B \rightarrow C \rightarrow A)$$

$$= a(A \rightarrow B) + a(B \rightarrow C) + a(C \rightarrow A).$$

Sau đó, tác giả:

- áp dụng IG trên từng đoạn đường đi;

- áp dụng Guided IG trên từng đoạn đường đi;
- cộng các attribution của từng đoạn lại để thu được attribution trên closed path.

Nếu phương pháp attribution hoạt động tốt, kết quả thu được phải gần với ground truth:

$$a_i \approx 0.$$

5.1.4 Thiết lập thí nghiệm

Trong thực nghiệm, tác giả:

- lấy 200 ảnh ngẫu nhiên từ tập validation của ImageNet;
- tạo 50 closed path ngẫu nhiên cho mỗi ảnh.

Tổng số đường đi được đánh giá là:

$$200 \times 50 = 10\,000$$

path samples.

Sai số được đo bằng Mean Squared Error (MSE) giữa attribution thu được và ground truth attribution. Sai số được tính trung bình trên:

Guided IG có MSE thấp hơn IG trong mọi mô hình.

- tất cả ảnh;
- tất cả pixel;
- tất cả channel màu.

	MobileNet	Inception	ResNet
IG	3.817e-07	5.938e-07	6.707e-07
Guided IG	7.320e-08	1.442e-07	1.857e-07

Table 1: Closed path mean squared error for IG and Guided IG.

Hình 3:

5.2 Quantitative evaluation

Metrics.

Tác giả so sánh Guided IG với các phương pháp attribution khác bằng hai độ đo chính: AUC-ROC và Softmax Information Curve (SIC) AUC.

5.2.1 AUC-ROC

AUC-ROC đánh giá mức độ phù hợp giữa bản đồ attribution và vùng quan trọng được đánh dấu bởi con người (*human annotations*).

Trong phương pháp này, các giá trị attribution được xem như điểm dự đoán (*prediction scores*) của một bộ phân loại nhị phân, trong đó:

- pixel có attribution cao được xem là có khả năng thuộc vùng quan trọng;
- pixel có attribution thấp được xem là ít quan trọng.

Ví dụ, giả sử một attribution map có giá trị:

Pixel	Attribution
<i>A</i>	0.9
<i>B</i>	0.7
<i>C</i>	0.1
<i>D</i>	0.05

Một ngưỡng (*threshold*) được thay đổi để phân loại pixel thành vùng quan trọng hoặc không quan trọng.

Ví dụ:

$$\text{threshold} = 0.8$$

thì:

- pixel A được dự đoán là quan trọng;
- các pixel B, C, D được dự đoán là không quan trọng.

Khi thay đổi threshold, các cặp giá trị True Positive Rate (TPR) và False Positive Rate (FPR) tạo thành đường cong ROC. Diện tích dưới đường cong này được sử dụng làm chỉ số đánh giá:

$$AUC_{ROC}.$$

AUC-ROC càng cao nghĩa là attribution map càng phù hợp với vùng quan trọng được con người đánh dấu.

5.2.2 Softmax Information Curve (SIC) AUC

Khác với AUC-ROC, SIC AUC không yêu cầu đánh giá của con người. Thay vào đó, phương pháp này đánh giá liệu attribution có xác định đúng vùng mà mô hình thực sự sử dụng để đưa ra dự đoán hay không.

Quy trình gồm:

1. Một attribution method tạo ra saliency map.
2. Chỉ giữ lại các vùng có attribution cao.

3. Đưa các vùng này vào mô hình dự đoán.
4. Đo giá trị softmax score của lớp dự đoán.

Một attribution tốt cần tập trung vào những vùng quan trọng đối với mô hình. Do đó, khi giữ lại các vùng có attribution cao, softmax score của mô hình sẽ tăng nhanh hơn.

Vì vậy, phương pháp tốt sẽ đạt diện tích dưới đường cong SIC lớn hơn.
Tất cả phương pháp cần baseline đều sử dụng:

- 200 bước tích phân;
- baseline màu đen.

5.2.3 Datasets

Tác giả đánh giá các phương pháp trên ba loại dataset:

- hai dataset ảnh tự nhiên: ImageNet và Open Images;
- một dataset ảnh y tế: Diabetic Retinopathy (DR), dùng trong chẩn đoán bệnh võng mạc tiểu đường.

5.3 Phân tích kết quả

(SIC AUC)	ImageNet			Open Images
Method	MobileNet	Inception	ResNet	ResNet
Edge	0.300	0.371	0.405	0.537
Gradients	0.368	0.431	0.510	0.595
IG	0.402	0.499	0.544	0.694
Blur IG	0.411	0.501	0.560	0.659
GIG(0)	0.423	0.516	0.550	0.634
GIG(20)	0.453	0.546	0.584	0.701
GIG(40)	0.453	0.551	0.592	0.734
GradCAM	0.691	0.739	0.763	0.662
XRAI				
+IG	0.671	0.736	0.755	0.843
+GIG(40)	0.692	0.752	0.771	0.866

Hình 4: SIC AUC results for Guided IG and other attribution methods. All methods use black and white baseline if required. Values in bold indicate the best results.

(AUC) Method	ImageNet			Open Images ResNet	DR [14]
	MobileNet	Inception	ResNet		
Edge	0.611	0.610	0.611	0.606	0.643
Gradients	0.614	0.634	0.650	0.505	0.801
IG	0.629	0.655	0.669	0.557	0.833
Blur IG	0.652	0.662	0.663	0.619	0.830
GIG (0)	0.705	0.712	0.711	0.630	0.619
GIG (20)	0.691	0.696	0.706	0.624	0.863*
GradCAM	0.776	0.761	0.755	0.474	0.837
Smoothgrad					
+IG	0.742	0.773	0.781	0.662	0.637
+GIG(0)	0.745	0.776	0.776	0.649	0.632
+GIG(20)	0.767	0.795	0.799	0.685	0.645
XRAI					
+IG	0.731	0.765	0.762	0.631	0.793
+GIG(0)	0.838*	0.829*	0.821*	0.718	0.630
+GIG(20)	0.808	0.819	0.809	0.719*	0.831

Hình 5: Giá trị AUC trung bình của các phương pháp attribution khi sử dụng baseline màu đen. Giá trị AUC cao hơn biểu thị hiệu quả attribution tốt hơn. Giá trị in đậm biểu thị kết quả tốt nhất trong từng nhóm, trong khi ký hiệu * biểu thị kết quả tốt nhất trên toàn bộ các phương pháp.

Từ các bảng kết quả, tác giả đưa ra một số nhận xét:

- **SmoothGrad và Guided IG giảm các loại nhiễu tương tự.**

SmoothGrad giảm nhiễu bằng cách lấy trung bình attribution trên nhiều phiên bản nhiễu của cùng một ảnh, trong khi Guided IG giảm nhiễu bằng cách thay đổi đường tích phân. Vì vậy, khi kết hợp:

SmoothGrad + Guided IG

mức cải thiện thường không lớn do hai phương pháp có thể đang xử lý cùng một nguồn nhiễu.

- **Ảnh hưởng của anchor.**

Khi thêm anchor vào Guided IG, ví dụ:

GIG(20)

kết quả được cải thiện đáng kể.

Anchor giúp hạn chế đường đi của Guided IG không lệch quá xa khỏi đường thẳng ban đầu, đồng thời vẫn cho phép tránh các vùng có gradient bất thường.

- **Kết hợp với XRAI.**

XRAI thực hiện gom attribution theo các vùng ảnh thay vì từng pixel riêng lẻ. Khi kết hợp:


XRAI + GuidedIG

phương pháp thường đạt kết quả tốt trên nhiều mô hình.

- **Kết quả trên dataset DR.**

Trên ảnh võng mạc, các phương pháp làm mờ không phải lúc nào cũng cải thiện kết quả. Nguyên nhân là các tổn thương trong ảnh y tế thường có kích thước nhỏ và cần attribution thưa (*sparse attribution*).

Nếu làm mờ quá mức, các vùng tổn thương quan trọng có thể bị hòa trộn với vùng xung quanh, làm mất các chi tiết quan trọng.



(a) IG attribution

(b) Guided IG attribution

Figure 7: Comparison of IG and Guided IG on a retina image [6] used in diagnosing diabetic retinopathy.

Hình 6: Comparison of IG and Guided IG on a retina image used in diagnosing diabetic retinopathy.




Figure 8: Visual comparison of GIG and IG. See how GIG is more focused around the basketball compared to IG.

Hình 7: Visual comparison between IG and Guided IG. Guided IG produces more concentrated attribution around the relevant object compared with IG.