

A Unified Approach to Interpreting Model Predictions

Le-Van Thai

June 2026

1 Types of XAI

- Model-Agnostic Techniques (không cần biết cấu trúc bên trong của mô hình, chỉ dựa trên input và output của mô hình đã được huấn luyện): LIME, SHAP, Anchor.
- Visualization-Based Techniques (giải thích bằng cách trực quan hóa những vùng hoặc đặc trưng quan trọng): Grad-CAM.
- Gradient-Based Techniques (cần truy cập vào bên trong mô hình và sử dụng gradient để xác định mức độ đóng góp của từng đặc trưng): Integrated Gradients.

2 Introduction

SHAP (SHapley Additive exPlanations) - Phương pháp giải thích mô hình dựa trên giá trị Shapley

Three main contributions:

- Kết luận: Mọi cách giải thích cho một dự đoán của mô hình đều có thể được xem như một mô hình riêng, gọi là mô hình giải thích (explanation model) -> Giúp định nghĩa lớp các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính (additive feature attribution methods) (Section 2), qua đó thống nhất sáu phương pháp hiện có.
- Chứng minh rằng các kết quả từ lý thuyết trò chơi (game theory) đảm bảo sự tồn tại của một nghiệm duy nhất có thể được áp dụng cho toàn bộ lớp (class) các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính (Section 3) -> Dựa trên đó, đề xuất SHAP values -> một thước đo thống nhất về mức độ quan trọng của các đặc trưng, mà nhiều phương pháp trước thực chất chỉ là các phép xấp xỉ của thước đo này (section 4)

- Đề xuất phương pháp dùng để ước lượng giá trị SHAP và chứng minh chúng phù hợp hơn với trực giác của con người thông qua các nghiên cứu người dùng, đồng thời có khả năng phân biệt giữa các lớp (classes) đầu ra của mô hình hiệu quả hơn so với nhiều phương pháp trước (section 5).

3 Additive Feature Attribution Methods – Các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính

Contribution 1. Mọi lời giải thích cho một dự đoán của mô hình đều có thể được biểu diễn dưới dạng một *mô hình giải thích (explanation model)*. Từ đó, bài báo định nghĩa lớp *Additive Feature Attribution Methods*, thống nhất sáu phương pháp giải thích đã tồn tại trước đó trong cùng một khuôn khổ lý thuyết.

Đối với các mô hình đơn giản, lời giải thích tốt nhất chính là bản thân mô hình vì nó mô tả trực tiếp cách thức đưa ra dự đoán. Tuy nhiên, đối với các mô hình phức tạp như ensemble methods hoặc Deep Neural Networks, việc sử dụng chính mô hình làm lời giải thích là không khả thi do cấu trúc quá phức tạp để con người diễn giải. Vì vậy, cần xây dựng một mô hình đơn giản hơn nhằm xấp xỉ hành vi của mô hình gốc.

Gọi f là mô hình dự đoán cần được giải thích và g là mô hình giải thích. Bài báo tập trung vào các phương pháp giải thích cục bộ (*local explanation methods*), tức chỉ giải thích dự đoán $f(x)$ đối với một mẫu dữ liệu cụ thể x , tương tự như cách tiếp cận của LIME.

Ý tưởng chính

Giả sử đầu vào của mô hình là

$$x = (\text{Tuổi} = 45, \text{Huyết áp} = 140, \text{Cholesterol} = 220, \text{BMI} = 28),$$

đây là dữ liệu đầy đủ được đưa vào mô hình dự đoán f .

Bước 1. Đơn giản hóa đầu vào

Thay vì làm việc trực tiếp với x , SHAP xây dựng một đầu vào đơn giản hóa ký hiệu là x' . Đầu vào này không chứa giá trị thực của các đặc trưng mà chỉ biểu thị đặc trưng nào được giữ lại và đặc trưng nào bị loại bỏ.

Đặc trưng	x	x'
Tuổi	45	1
Huyết áp	140	1
Cholesterol	220	0
BMI	28	0

Bảng 1: Ví dụ về đầu vào đơn giản hóa x' .

Như vậy, x' chỉ biểu diễn đặc trưng nào được sử dụng thay vì lưu giá trị thực của các đặc trưng.

Bước 2. Ánh xạ về đầu vào gốc

Do mô hình dự đoán f không thể xử lý trực tiếp đầu vào dạng nhị phân x' , SHAP sử dụng một hàm ánh xạ

$$h_x(x')$$

để chuyển x' thành đầu vào hợp lệ mà mô hình có thể xử lý. Có thể xem h_x là cầu nối giữa không gian đầu vào đơn giản hóa và dữ liệu gốc.

Bước 3. Xây dựng mô hình giải thích

Từ các đầu vào đơn giản hóa, SHAP xây dựng một mô hình giải thích g sao cho

$$g(z') \approx f(h_x(z')).$$

Điều này có nghĩa là khi thay đổi tập các đặc trưng được giữ hoặc loại bỏ trong z' , mô hình giải thích g sẽ cho kết quả gần với dự đoán của mô hình gốc f . Dựa trên sự thay đổi của dự đoán, SHAP có thể ước lượng mức độ đóng góp của từng đặc trưng đối với kết quả cuối cùng.

3.1 Definition 1: Additive Feature Attribution Methods

Theo bài báo, một mô hình giải thích thuộc lớp *Additive Feature Attribution Methods* nếu có dạng

****Phương trình 1****

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i = \phi_0 + \phi_1 z'_1 + \phi_2 z'_2 + \dots + \phi_M z'_M.$$

Trong đó:

- $z' \in \{0, 1\}^M$ là đầu vào đơn giản hóa gồm M đặc trưng;
- M là số lượng đặc trưng;
- $\phi_i \in \mathbb{R}$ là mức độ đóng góp của đặc trưng thứ i ;
- ϕ_0 là giá trị cơ sở (*base value*), biểu diễn đầu ra của mô hình khi không có đặc trưng nào được sử dụng.

Như vậy, dự đoán của mô hình giải thích được biểu diễn dưới dạng tổng của giá trị cơ sở và các mức đóng góp của từng đặc trưng. Đây là nền tảng chung của các phương pháp giải thích như LIME, DeepLIFT, Layer-wise Relevance Propagation và SHAP.

Ví dụ minh họa

Giả sử mô hình có ba đặc trưng gồm Tuổi, BMI và Cholesterol. Sau khi xây dựng mô hình giải thích, ta thu được các hệ số

$$\phi_0 = 0.20, \quad \phi_1 = 0.15, \quad \phi_2 = 0.30, \quad \phi_3 = 0.10.$$

Nếu cả ba đặc trưng đều được giữ lại, tức là

$$z' = [1, 1, 1],$$

thì đầu ra của mô hình giải thích là

$$\begin{aligned} g(z') &= \phi_0 + \phi_1 + \phi_2 + \phi_3 \\ &= 0.20 + 0.15 + 0.30 + 0.10 \\ &= 0.75. \end{aligned}$$

Có thể hiểu trực quan rằng

$$\text{Dự đoán} = \text{Giá trị cơ sở} + \sum \text{Đóng góp của từng đặc trưng.}$$

Nói cách khác, SHAP phân rã dự đoán của mô hình thành tổng các mức đóng góp của từng đặc trưng, từ đó giúp giải thích rõ ràng vì sao mô hình đưa ra một dự đoán cụ thể.

3.2 LIME

LIME hoạt động theo ba bước:

1. Sinh nhiều mẫu dữ liệu xung quanh điểm cần giải thích.
2. Dùng mô hình gốc dự đoán cho các mẫu này và gán trọng số cao hơn cho các mẫu ở gần điểm đang xét.
3. Huấn luyện một mô hình tuyến tính đơn giản để xấp xỉ hành vi của mô hình gốc trong vùng lân cận đó, từ đó sử dụng các hệ số của mô hình tuyến tính làm lời giải thích về mức độ đóng góp của từng đặc trưng.

3.3 DeepLIFT

Khác với LIME (xấp xỉ mô hình bằng một mô hình tuyến tính cục bộ), DeepLIFT giải thích bằng cách so sánh với một đầu vào tham chiếu.

Ví dụ:

- Ảnh gốc $\rightarrow$ mô hình dự đoán 90% là chó.
- Ảnh tham chiếu (toàn màu đen) $\rightarrow$ mô hình dự đoán 5% là chó.

Khi đó

$$\Delta o = 90\% - 5\% = 85\%.$$

DeepLIFT sẽ tính xem mỗi đặc trưng (pixel hoặc neuron) đã đóng góp bao nhiêu vào 85% này. Tổng đóng góp của tất cả các đặc trưng sẽ đúng bằng 85%, tức là thỏa mãn tính chất *summation-to-delta*. Đây cũng chính là lý do DeepLIFT có thể được biểu diễn dưới dạng cộng tính, tương tự như SHAP và LIME.

3.4 Layer-Wise Relevance Propagation – Lan truyền mức độ liên quan theo từng lớp

Có thể hiểu đơn giản rằng:

- **DeepLIFT**: so sánh với một đầu vào tham chiếu (*reference input*), ví dụ ảnh đen hoặc giá trị trung bình.
- **LRP**: là trường hợp đặc biệt của DeepLIFT, trong đó đầu vào tham chiếu luôn được chọn là 0.

Do cả hai phương pháp đều phân rã đầu ra của mô hình thành tổng đóng góp của từng đặc trưng, nên chúng đều có thể biểu diễn dưới dạng cộng tính (*additive form*) và được SHAP thống nhất trong cùng một lý thuyết.

3.5 Classic Shapley Value Estimation

Ba phương pháp này sử dụng các công thức cổ điển của lý thuyết trò chơi hợp tác (cooperative game theory) để giải thích dự đoán của mô hình, bao gồm: Shapley Regression Values, Shapley Sampling Values, Quantitative Input Influence. Khác với LIME, DeepLIFT và LRP, ba phương pháp này đều dựa trực tiếp trên giá trị Shapley trong lý thuyết trò chơi. Ý tưởng chung là:

- xem mỗi đặc trưng như một "người chơi" trong một trò chơi hợp tác (cooperative game theory)
- mỗi dự đoán của mô hình là phần thưởng của trò chơi;
- giá trị Shapley của một đặc trưng chính là mức đóng góp trung bình của đặc trưng đó vào dự đoán, khi xét trên tất cả các thứ tự hoặc tổ hợp có thể có của các đặc trưng.

Do đều biểu diễn dự đoán dưới dạng tổng các mức đóng góp của từng đặc trưng, cả ba phương pháp đều phù hợp với additive feature attribution mà SHAP đề xuất.

Shapley Regression Values. Phương pháp này yêu cầu huấn luyện lại mô hình trên mọi tập con đặc trưng $S \subseteq F$, trong đó F là tập hợp tất cả các đặc trưng.

Đối với mỗi đặc trưng i , phương pháp sẽ tính mức độ ảnh hưởng của việc đưa đặc trưng đó vào mô hình bằng cách:

- huấn luyện một mô hình $f_{S \cup \{i\}}$ trên tập đặc trưng S có thêm đặc trưng i ;
- huấn luyện một mô hình khác f_S chỉ sử dụng tập đặc trưng S .

Sau đó, mức đóng góp của đặc trưng i được xác định bằng sự khác biệt giữa hai dự đoán:

$$f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S),$$

trong đó x_S là các giá trị của mẫu dữ liệu tương ứng với tập đặc trưng S .

Do mức ảnh hưởng của một đặc trưng phụ thuộc vào các đặc trưng khác trong mô hình, phép so sánh trên phải được thực hiện với mọi tập con $S \subseteq F \setminus \{i\}$. Giá trị Shapley của đặc trưng i sau đó được tính bằng trung bình có trọng số của tất cả các mức thay đổi này:

****Phương trình 4****

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)].$$

Để hiểu ý nghĩa của hệ số trọng số trong công thức Shapley, giả sử mô hình chỉ có ba đặc trưng A , B và C , và cần tính giá trị Shapley của đặc trưng A .

Khi đó, tất cả các tập con không chứa A là

$$S = \{\emptyset, \{B\}, \{C\}, \{B, C\}\}.$$

Tương ứng với mỗi tập con S , ta tính mức đóng góp cận biên (*marginal contribution*) của đặc trưng A :

$$\begin{aligned} f(A) - f(\emptyset), \\ f(A, B) - f(B), \\ f(A, C) - f(C), \\ f(A, B, C) - f(B, C). \end{aligned}$$

Nếu chỉ lấy trung bình cộng của bốn hiệu số trên,

$$\frac{\Delta_1 + \Delta_2 + \Delta_3 + \Delta_4}{4},$$

thì kết quả sẽ không đúng theo lý thuyết trò chơi hợp tác. Nguyên nhân là do mỗi tập con S không xuất hiện với cùng tần suất trong tất cả các thứ tự thêm đặc trưng.

Ví dụ, với ba đặc trưng A , B và C , có tất cả

$$3! = 6$$

thứ tự thêm đặc trưng:

$$ABC, BAC, CAB, BCA, ACB, CBA.$$

Xét trường hợp $S = \{B\}$. Điều này có nghĩa là trước khi thêm A thì chỉ có đặc trưng B . Trong sáu thứ tự trên, chỉ có duy nhất thứ tự

$$BAC$$

thỏa mãn điều kiện này. Vì vậy, hiệu số

$$f(A, B) - f(B)$$

chỉ đại diện cho $\frac{1}{6}$ số trường hợp.

Ngược lại, nếu $S = \emptyset$, nghĩa là A xuất hiện đầu tiên, thì có hai thứ tự thỏa mãn:

$$ABC, \quad ACB.$$

Do đó, mức đóng góp

$$f(A) - f(\emptyset)$$

đại diện cho $\frac{2}{6}$ số trường hợp và cần được gán trọng số lớn hơn.

Tổng quát, giả sử có $|F|$ đặc trưng và xét một tập con S đứng trước đặc trưng i . Có

$$|S|!$$

cách sắp xếp các đặc trưng trong S , và

$$(|F| - |S| - 1)!$$

cách sắp xếp các đặc trưng còn lại sau i . Do đó, số thứ tự mà tập S xuất hiện trước đặc trưng i là

$$|S|!(|F| - |S| - 1)!.$$

Vì tổng số thứ tự của tất cả các đặc trưng là

$$|F|!,$$

nên xác suất đặc trưng i được thêm vào ngay sau tập S là

$$\frac{|S|!(|F| - |S| - 1)!}{|F|!}.$$

Có thể hình dung rằng các đặc trưng lần lượt tham gia vào một “trò chơi” theo mọi thứ tự có thể. Mỗi khi đặc trưng i được thêm vào, ta đo mức thay đổi của dự đoán mô hình, hay còn gọi là *marginal contribution*. Vì mỗi tập con S xuất hiện với số lượng thứ tự khác nhau, các mức đóng góp này không thể được lấy trung bình đơn giản mà phải nhân với trọng số

$$\frac{|S|!(|F| - |S| - 1)!}{|F|!},$$

chính là tỷ lệ số thứ tự mà tập S đứng trước đặc trưng i . Đây là lý do hệ số trọng số này xuất hiện trong công thức Shapley.

Nếu đặt

$$\phi_0 = f_\emptyset(\emptyset),$$

thì mô hình giải thích của Shapley Regression Values có cùng dạng với Phương trình (1). Vì vậy, đây cũng là một phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính (*Additive Feature Attribution Method*).

Shapley Sampling Values. được đề xuất nhằm mở rộng việc tính giá trị Shapley cho mọi loại mô hình, thông qua hai ý tưởng chính:

1. sử dụng lấy mẫu (sampling) để xấp xỉ công thức Shapley trong Phương trình (4): Thay vì tính hơn một triệu tập con, chỉ lấy ngẫu nhiên vài nghìn tập.
2. thay vì huấn luyện lại mô hình sau khi loại bỏ một đặc trưng, phương pháp ước lượng ảnh hưởng của việc loại bỏ đặc trưng bằng cách lấy trung bình trên các mẫu trong tập dữ liệu huấn luyện

Giả sử mô hình được huấn luyện với ba đặc trưng gồm Age, BMI và Cholesterol. Ta muốn đánh giá mức độ đóng góp của đặc trưng Cholesterol.

Đối với **Shapley Regression Values**, nếu muốn biết điều gì xảy ra khi không sử dụng Cholesterol, phương pháp sẽ huấn luyện lại một mô hình mới chỉ với hai đặc trưng Age và BMI, sau đó sử dụng mô hình này để dự đoán.

Ngược lại, **Shapley Sampling Values** không huấn luyện lại mô hình. Thay vào đó, đặc trưng Cholesterol được “che” bằng cách thay thế giá trị của nó bởi các giá trị được lấy ngẫu nhiên từ tập dữ liệu huấn luyện.

Ví dụ, giả sử bệnh nhân cần giải thích có dữ liệu:

Age	BMI	Cholesterol
60	30	250

Để mô phỏng trường hợp “không biết” giá trị Cholesterol, phương pháp lần lượt thay thế Cholesterol bằng các giá trị lấy từ những mẫu khác trong tập huấn luyện, chẳng hạn:

(60, 30, 180),

(60, 30, 220),

(60, 30, 195),

sau đó chạy mô hình trên từng mẫu và lấy trung bình các kết quả dự đoán. Về mặt toán học, quá trình này chính là phép xấp xỉ kỳ vọng có điều kiện

$$E[f(x) \mid \text{không biết Cholesterol}],$$

tức là giá trị kỳ vọng của đầu ra mô hình khi đặc trưng Cholesterol bị che đi.

Nhờ vậy, phương pháp không cần huấn luyện lại mô hình trên mọi tập con đặc trưng mà chỉ cần ước lượng giá trị Shapley thông qua một số lượng nhỏ các mẫu được lấy ngẫu nhiên. Điều này giúp giảm đáng kể chi phí tính toán, thay

vì phải xét toàn bộ $2^{|F|}$ tập con đặc trưng.

Do mô hình giải thích của Shapley Sampling Values có cùng dạng với Shapley Regression Values, phương pháp này cũng thuộc nhóm các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính.

Quantitative Input Influence. tổng quát hơn, không chỉ giới hạn ở việc đánh giá mức độ đóng góp của các đặc trưng.

Tuy nhiên, trong quá trình xây dựng phương pháp, QII cũng đề xuất một thuật toán lấy mẫu để xấp xỉ giá trị Shapley, gần như giống hệt với Shapley Sampling Values.

Do đó, QII cũng được xem là một phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính.

3.6 Simple Properties Uniquely Determine Additive Feature Attributions

Contribution 2. Chứng minh rằng các kết quả từ lý thuyết trò chơi (game theory) đảm bảo sự tồn tại của một nghiệm duy nhất có thể được áp dụng cho toàn bộ lớp (class) các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính (Section 3)

Một điểm đáng chú ý của lớp các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính (additive feature attribution methods) là trong lớp phương pháp này chỉ tồn tại một nghiệm duy nhất đồng thời thỏa mãn ba tính chất mong muốn.

Mặc dù ba tính chất này đã quen thuộc trong các phương pháp ước lượng giá trị Shapley cổ điển, trước đây người ta chưa nhận ra rằng chúng cũng có thể được áp dụng cho toàn bộ lớp các phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính.

3.7 Tính chất 1. Độ chính xác cục bộ (Local Accuracy)

Property 1 (Local accuracy) Theo Định nghĩa 1, mô hình giải thích của SHAP phải thỏa mãn

$$f(x) = g(x') = \phi_0 + \sum_{i=1}^M \phi_i x'_i. \quad (1)$$

Nói cách khác, mô hình giải thích $g(x')$ phải cho cùng kết quả với mô hình gốc $f(x)$, trong đó

$$x = h_x(x').$$

Giá trị

$$\phi_0 = f(h_x(\mathbf{0}))$$

được gọi là *giá trị cơ sở* (*baseline value*), biểu diễn đầu ra của mô hình khi tất cả các đặc trưng trong đầu vào đơn giản hóa đều bị tắt (tức là được xem như không tồn tại).

3.8 Property 2 (Missingness)

Tính chất thứ hai là Missingness. Nếu đầu vào đơn giản hóa biểu diễn sự có mặt của các đặc trưng, thì những đặc trưng không xuất hiện trong đầu vào sẽ không được gán bất kỳ mức đóng góp nào.

Tất cả các phương pháp đã trình bày ở trên đều thỏa mãn tính chất này.

3.9 Property 3: Tính nhất quán (Consistency)

Tính nhất quán (*Consistency*) yêu cầu rằng nếu một mô hình được thay đổi sao cho mức đóng góp của một đặc trưng luôn tăng lên hoặc ít nhất không giảm, bất kể giá trị của các đặc trưng còn lại, thì giá trị đóng góp được gán cho đặc trưng đó cũng không được giảm.

Cho z' là vector nhị phân biểu diễn tập đặc trưng đang được giữ lại. Chẳng hạn,

$$z' = (1, 1, 1)$$

nghĩa là cả ba đặc trưng đều được sử dụng, trong khi

$$z' \setminus i = (1, 0, 1)$$

là đầu vào thu được sau khi loại bỏ đặc trưng thứ i . Nói cách khác, $z' \setminus i$ là phiên bản của z' không chứa đặc trưng i .

Theo bài báo, hàm

$$f_x(z') = f(h_x(z'))$$

biểu diễn dự đoán của mô hình khi chỉ giữ lại các đặc trưng được chỉ định bởi z' . Vì vậy,

$$f_x(z') - f_x(z' \setminus i)$$

chính là mức thay đổi của dự đoán khi thêm đặc trưng i , hay còn gọi là *marginal contribution* của đặc trưng đó.

Xét hai mô hình f và f' . Giả sử ở mô hình cũ, đặc trưng BMI chỉ có mức ảnh hưởng vừa phải, còn ở mô hình mới sau khi huấn luyện lại, BMI trở nên quan trọng hơn.

Ví dụ:

	Có BMI	Không BMI
Model cũ	0.80	0.70
Model mới	0.92	0.70

Khi đó, mức đóng góp của BMI trong hai mô hình lần lượt là

$$0.80 - 0.70 = 0.10,$$

và

$$0.92 - 0.70 = 0.22.$$

BMI có ảnh hưởng lớn hơn trong mô hình mới.

Tính nhất quán yêu cầu rằng nếu với **mọi** tập đặc trưng z' ta đều có

$$f'_x(z') - f'_x(z' \setminus i) \geq f_x(z') - f_x(z' \setminus i),$$

tức là việc thêm đặc trưng i luôn làm dự đoán của mô hình mới tăng nhiều hơn hoặc bằng mô hình cũ, thì giá trị SHAP của đặc trưng đó cũng không được giảm:

$$\phi_i(f', x) \geq \phi_i(f, x).$$

Ví dụ, nếu

$$\phi_{\text{BMI}}(f, x) = 0.15,$$

thì sau khi BMI trở nên quan trọng hơn trong mô hình mới, ta không thể có

$$\phi_{\text{BMI}}(f', x) = 0.12.$$

Điều này sẽ vi phạm tính chất *Consistency*. Nói cách khác, khi mức đóng góp thực sự của một đặc trưng tăng lên trong mọi trường hợp, giá trị SHAP của đặc trưng đó cũng phải tăng hoặc ít nhất giữ nguyên.

3.10 Định lý 1

Dựa trên ba tính chất đã trình bày, tác giả chứng minh rằng chỉ tồn tại duy nhất một phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính. Cụ thể, mức đóng góp của đặc trưng thứ i được xác định bởi

** Phương trình 8**

$$\phi_i(f, x) = \sum_{z' \subseteq x'} \frac{|z'|!(M - |z'| - 1)!}{M!} [f_x(z') - f_x(z' \setminus i)]. \quad (2)$$

Trong đó:

- $|z'|$ là số lượng đặc trưng đang được giữ lại (số phần tử khác 0 trong z');
- $z' \subseteq x'$ là tất cả các đầu vào đơn giản hóa mà tập đặc trưng được giữ lại là tập con của các đặc trưng xuất hiện trong x' .

Định lý này được suy ra từ các kết quả trong lý thuyết trò chơi hợp tác, trong đó các giá trị ϕ_i chính là *giá trị Shapley* (Shapley values). *H. Peyton Young* đã chứng minh rằng giá trị Shapley là nghiệm duy nhất thỏa mãn các tiên đề của lý thuyết trò chơi hợp tác, tương ứng với các tính chất *Local Accuracy* và *Consistency*. Trong bài báo SHAP, tác giả bổ sung thêm tính chất *Missingness* để mở rộng kết quả này sang lớp các phương pháp giải thích theo dạng cộng tính.

Do đó, với một hàm ánh xạ đầu vào đơn giản hóa h_x đã cho, Định lý 1 khẳng định rằng chỉ tồn tại duy nhất một phương pháp gán mức độ đóng góp của đặc trưng theo dạng cộng tính, đó chính là **SHAP values**.

Kết quả này cũng cho thấy mọi phương pháp không dựa trên giá trị Shapley đều sẽ vi phạm ít nhất một trong hai tính chất *Local Accuracy* hoặc *Consistency* (các phương pháp trong Mục 2 vốn đã thỏa mãn tính chất *Missingness*).


Kết luận. Chỉ tồn tại duy nhất một mô hình giải thích đồng thời thỏa mãn:

- Định nghĩa 1 (Additive Feature Attribution Methods);
- Tính chất 1: Local Accuracy;
- Tính chất 2: Missingness;
- Tính chất 3: Consistency.

4 SHAP (SHapley Additive exPlanation) Values

Contribution 2. Dựa trên kết quả ở Mục 2 và Mục 3, tác giả đề xuất **SHAP values** như một thước đo thống nhất về mức độ quan trọng của các đặc trưng. Nhiều phương pháp giải thích trước đây thực chất chỉ là các phép xấp xỉ của thước đo này.

Giá trị SHAP được định nghĩa là giá trị Shapley của hàm kỳ vọng có điều kiện (*conditional expectation function*) của mô hình gốc. Do đó, chúng chính là nghiệm duy nhất của Định lý 1.



Hình 1: Giá trị SHAP gán cho mỗi đặc trưng mức thay đổi của giá trị kỳ vọng của dự đoán mô hình khi biết thêm thông tin về đặc trưng đó. SHAP giải thích cách chuyển từ giá trị cơ sở $E[f(z)]$ (dự đoán trung bình của mô hình khi chưa biết bất kỳ đặc trưng nào) đến dự đoán hiện tại $f(x)$. Hình chỉ minh họa một thứ tự thêm đặc trưng; trên thực tế, giá trị SHAP được tính bằng cách lấy trung bình mức đóng góp của mỗi đặc trưng trên tất cả các thứ tự thêm đặc trưng có thể xảy ra.

Trong SHAP, mô hình giải thích được định nghĩa bởi

$$f_x(z') = f(h_x(z')) = E[f(z) | z_S], \quad (3)$$

trong đó S là tập các chỉ số có giá trị bằng 1 trong z' . Điều này có nghĩa là mô hình chỉ biết các đặc trưng thuộc S , còn các đặc trưng khác được xem là bị thiếu.

Với cách định nghĩa này, hàm ánh xạ đầu vào đơn giản hóa được ngầm định là

$$h_x(z') = z_S,$$

trong đó z_S chỉ chứa các đặc trưng thuộc tập S .

Tuy nhiên, hầu hết các mô hình học máy không thể xử lý trực tiếp dữ liệu có các đặc trưng bị thiếu. Vì vậy, thay vì tính trực tiếp $f(z_S)$, SHAP sử dụng kỳ vọng có điều kiện

$$E[f(z) | z_S],$$

tức là giá trị kỳ vọng của đầu ra mô hình khi biết các đặc trưng trong S và lấy trung bình trên các đặc trưng còn lại.

Nhờ cách định nghĩa này, SHAP vừa thống nhất các phương pháp dựa trên giá trị Shapley như *Shapley Regression Values*, *Shapley Sampling Values* và *Quantitative Input Influence*, vừa thiết lập được mối liên hệ với các phương pháp như *LIME*, *DeepLIFT* và *Layer-wise Relevance Propagation (LRP)*.

Việc tính chính xác giá trị SHAP có độ phức tạp rất cao. Do đó, bài báo đề xuất nhiều phương pháp xấp xỉ, bao gồm các phương pháp độc lập với mô hình (*model-agnostic*) như *Shapley Sampling Values* và *Kernel SHAP*, cùng các phương pháp dành riêng cho từng loại mô hình (*model-specific*) như *Max SHAP* và *Deep SHAP*.

Trong thực tế, để việc tính toán trở nên khả thi, hai giả định thường được sử dụng là:

- các đặc trưng độc lập với nhau (*feature independence*);
- mô hình gần tuyến tính (*model linearity*).

Khi đó, mô hình giải thích SHAP được biểu diễn bởi

$$f(h_x(z')) = E[f(z) | z_S], \quad (4)$$

sau đó được viết lại thành

$$E_{z_{\bar{S}}|z_S}[f(z)], \quad (5)$$

nghĩa là lấy kỳ vọng trên các đặc trưng chưa biết $z_{\bar{S}}$ trong khi giữ cố định các đặc trưng thuộc S .

Nếu giả sử các đặc trưng độc lập với nhau, ta có

Phương trình 11

$$E_{z_{\bar{S}}}[f(z)], \quad (6)$$

do không cần điều kiện hóa theo z_S .

Cuối cùng, nếu giả sử thêm rằng mô hình gần tuyến tính, kỳ vọng trên tiếp tục được xấp xỉ bởi

****Phương trình 12****

$$f([z_S, E[z_{\bar{S}}]]). \quad (7)$$

Điều này có nghĩa là thay thế tất cả các đặc trưng chưa biết bằng giá trị trung bình của chúng, sau đó đưa trực tiếp vào mô hình để tính dự đoán.

4.1 Model-Agnostic Approximations - Các phương pháp xấp xỉ độc lập với mô hình

Nếu giả sử các đặc trưng độc lập với nhau khi xấp xỉ kỳ vọng có điều kiện thì giá trị SHAP có thể được ước lượng trực tiếp bằng phương pháp Shapley Sampling Values hoặc tương đương là phương pháp Quantitative Input Influence (QII). Mặc dù các phương pháp này có chi phí tính toán chấp nhận được khi số lượng đặc trưng đầu vào nhỏ, Kernel SHAP (được trình bày ở phần tiếp theo) yêu cầu ít lần đánh giá mô hình gốc hơn nhưng vẫn đạt được độ chính xác xấp xỉ tương đương.

Kernel SHAP (Linear LIME + Shapley Values). Kernel SHAP kết hợp ý tưởng của Linear LIME và giá trị Shapley để xây dựng một phương pháp giải thích độc lập với mô hình (*model-agnostic*). Khác với LIME, trong đó hàm mất mát, kernel trọng số và điều chuẩn được lựa chọn chủ yếu dựa trên kinh nghiệm (*heuristically*), Kernel SHAP xác định các thành phần này dựa trên lý thuyết trò chơi. Nhờ đó, nghiệm của bài toán hồi quy chính là giá trị SHAP, đồng thời đảm bảo ba tính chất *Local Accuracy*, *Missingness* và *Consistency*.

Trong LIME, với các lựa chọn mang tính kinh nghiệm, nghiệm của Phương trình LIME không nhất thiết trùng với giá trị Shapley. Do đó, mô hình giải thích có thể vi phạm các tính chất *Local Accuracy* hoặc *Consistency*, dẫn đến các kết quả giải thích thiếu trực quan trong một số trường hợp.

Để khắc phục hạn chế này, tác giả chỉ ra rằng không cần lựa chọn các tham số theo kinh nghiệm mà có thể xác định trực tiếp hàm mất mát, kernel trọng số và hàm điều chuẩn sao cho nghiệm của bài toán hồi quy đúng bằng giá trị SHAP.

Định lý 2 (Shapley Kernel)

Định lý 2 chỉ ra rằng để nghiệm của bài toán hồi quy trong LIME đúng bằng giá trị SHAP và đồng thời thỏa mãn ba tính chất *Local Accuracy*, *Missingness* và *Consistency*, các thành phần của bài toán tối ưu phải được xác định như sau.

Không sử dụng điều chuẩn (*regularization*):

$$\Omega(g) = 0.$$

=> phạt mô hình nếu quá phức tạp.

Điều này giúp mô hình giải thích tập trung hoàn toàn vào việc khớp với đầu ra của mô hình gốc mà không bị ràng buộc bởi hạng tử điều chuẩn.

Kernel trọng số (*Shapley Kernel*) được định nghĩa là

$$\pi_{x'}(z') = \frac{(M-1)}{\binom{M}{|z'|} |z'| (M - |z'|)},$$

trong đó:

- M là tổng số đặc trưng;
- $|z'|$ là số đặc trưng đang được giữ lại trong đầu vào đơn giản hóa z' .

Kernel này quy định mức độ quan trọng của từng mẫu khi thực hiện hồi quy. Các mẫu có rất ít hoặc rất nhiều đặc trưng được giữ lại sẽ được gán trọng số lớn hơn, từ đó đảm bảo kết quả hồi quy phù hợp với lý thuyết Shapley.

Hàm mất mát được xác định là

$$L(f, g, \pi_{x'}) = \sum_{z' \in Z} \pi_{x'}(z') (f(h_x(z')) - g(z'))^2.$$

Đây là hàm bình phương sai số có trọng số (*weighted least squares*), trong đó sai số giữa mô hình gốc f và mô hình giải thích g được nhân với Shapley Kernel. Với lựa chọn kernel và hàm mất mát này, nghiệm của bài toán hồi quy chính là giá trị SHAP.

4.2 Các phương pháp xấp xỉ SHAP dành riêng cho từng loại mô hình (Model-Specific Approximations)

Mặc dù Kernel SHAP cải thiện hiệu quả tính toán của các phương pháp giải thích độc lập với mô hình (*model-agnostic*), việc khai thác đặc điểm của từng loại mô hình cụ thể có thể giúp xây dựng các phương pháp xấp xỉ nhanh hơn.

Linear SHAP

Đối với các mô hình tuyến tính, nếu giả sử các đặc trưng đầu vào độc lập với nhau (Phương trình (11)), giá trị SHAP có thể được tính trực tiếp từ các hệ số của mô hình.

Hệ quả 1 (Linear SHAP). Với mô hình tuyến tính

$$f(x) = \sum_{j=1}^M w_j x_j + b,$$

ta có

$$\phi_0(f, x) = b,$$

và

$$\phi_j(f, x) = w_j (x_j - E[x_j]).$$

Kết quả này được suy ra từ Định lý 2 và Phương trình (11), đồng thời cũng đã được đề cập trong nghiên cứu của Štrumbelj và Kononenko.

Low-Order SHAP

Việc tính Kernel SHAP bằng hồi quy tuyến tính có độ phức tạp

$$O(2^M + M^3),$$

do đó chỉ hiệu quả khi số lượng đặc trưng M không quá lớn. Nếu sử dụng các phép xấp xỉ của kỳ vọng có điều kiện (Phương trình (11) hoặc (12)), việc tính toán có thể được đơn giản hóa đáng kể.

Max SHAP

Đối với các hàm lấy giá trị lớn nhất (*max function*), tác giả khai thác công thức hoán vị của giá trị Shapley để tính xác suất mỗi đầu vào trở thành giá trị lớn nhất.

Nhờ sắp xếp các giá trị đầu vào theo thứ tự, Max SHAP giảm độ phức tạp tính toán từ

$$O(M2^M)$$

xuống còn

$$O(M^2).$$

Điều này giúp việc tính giá trị SHAP cho các phép toán *max pooling* trở nên hiệu quả hơn.

Deep SHAP (DeepLIFT + Shapley Values)

Mặc dù Kernel SHAP có thể áp dụng cho mọi loại mô hình, bao gồm cả mạng nơ-ron sâu, việc tính toán vẫn khá tốn kém. Vì vậy, tác giả khai thác cấu trúc nhiều tầng của mạng nơ-ron để xây dựng Deep SHAP.

Ý tưởng của Deep SHAP xuất phát từ mối liên hệ giữa DeepLIFT và giá trị Shapley. Nếu coi giá trị tham chiếu (*reference value*) của DeepLIFT là giá trị kỳ vọng của đầu vào $E[x]$, thì DeepLIFT có thể được xem như một phép xấp xỉ của SHAP khi giả sử:

- các đặc trưng đầu vào độc lập với nhau;
- mô hình gần tuyến tính.

Tuy nhiên, các quy tắc lan truyền ngược của DeepLIFT được xây dựng chủ yếu dựa trên trực giác và kinh nghiệm. Do SHAP là phương pháp duy nhất thỏa mãn đồng thời ba tính chất *Local Accuracy*, *Missingness* và *Consistency*, tác giả điều chỉnh các quy tắc của DeepLIFT để thu được Deep SHAP.

Deep SHAP tính giá trị SHAP cho từng thành phần nhỏ của mạng (chẳng hạn như lớp tuyến tính, hàm kích hoạt hoặc lớp *max pooling*), sau đó kết hợp các giá trị này thông qua quy tắc lan truyền ngược để thu được giá trị SHAP của toàn bộ mạng.

Các hệ số lan truyền được xác định bởi

$$m_{x_j}^{f_3} = \frac{\phi_j(f_3, x)}{x_j - E[x_j]}, \quad (8)$$

$$m_{y_i}^{f_j} = \frac{\phi_i(f_j, y)}{y_i - E[y_i]}, \quad (9)$$

và được kết hợp theo quy tắc dây chuyền (*chain rule*)

$$m_{y_i}^{f_3} = \sum_{j=1}^2 m_{y_i}^{f_j} m_{x_j}^{f_3}, \quad (10)$$

từ đó xấp xỉ giá trị SHAP của toàn bộ mạng

$$\phi_i(f_3, y) \approx m_{y_i}^{f_3} (y_i - E[y_i]). \quad (11)$$

Nhờ tận dụng cấu trúc của mạng nơ-ron, Deep SHAP có thể tính giá trị SHAP nhanh hơn đáng kể so với Kernel SHAP, đồng thời tránh việc phải lựa chọn các quy tắc tuyến tính hóa theo kinh nghiệm như trong DeepLIFT. Thay vào đó, các phép tuyến tính hóa được suy ra trực tiếp từ giá trị SHAP của từng thành phần trong mạng.

Tóm tắt các biến thể SHAP

Phương pháp	Đối tượng áp dụng	Ý tưởng chính
Linear SHAP	Mô hình tuyến tính	Tính trực tiếp giá trị SHAP từ các hệ số của mô hình.
Low-Order SHAP	Mô hình có ít đặc trưng	Đơn giản hóa việc tính SHAP bằng cách xấp xỉ kỳ vọng có điều kiện.
Max SHAP	Hàm max hoặc lớp max pooling	Khai thác cấu trúc của phép toán max để giảm độ phức tạp tính toán.
Deep SHAP	Mạng nơ-ron sâu	Kết hợp DeepLIFT với giá trị Shapley, tính SHAP cho từng thành phần của mạng rồi lan truyền ngược để thu được SHAP của toàn bộ mô hình.

Bảng 2: Tóm tắt các phương pháp xấp xỉ SHAP dành riêng cho từng loại mô hình.

5 Computational and User Study Experiments

Tác giả đánh giá hiệu quả của giá trị SHAP thông qua hai phương pháp xấp xỉ là Kernel SHAP và Deep SHAP.

1. So sánh hiệu quả tính toán và độ chính xác của Kernel SHAP, LIME và Shapley Sampling Values.
2. Thực hiện các nghiên cứu người dùng (user studies) để so sánh mức độ phù hợp giữa kết quả giải thích của SHAP, DeepLIFT và LIME với trực giác của con người.

- Đánh giá khả năng giải thích của các phương pháp trên bài toán phân loại ảnh chữ số MNIST.

→ Kết quả cho thấy các giá trị SHAP phù hợp với trực giác của con người hơn các phương pháp không đồng thời thỏa mãn ba tính chất Local Accuracy, Missingness và Consistency.

5.1 Hiệu quả tính toán (Computational Efficiency)

Định lý 2 chỉ ra mối liên hệ giữa giá trị Shapley trong lý thuyết trò chơi và hồi quy tuyến tính có trọng số. Dựa trên mối liên hệ này, Kernel SHAP tính toán mức độ đóng góp của từng đặc trưng hiệu quả hơn các phương pháp lấy mẫu trước đây.

Các kết quả thực nghiệm cho thấy Kernel SHAP đạt được độ chính xác tương đương hoặc cao hơn trong khi cần ít lần đánh giá mô hình gốc hơn so với Shapley Sampling Values, đặc biệt khi kết hợp với hồi quy có điều chuẩn.

Thí nghiệm trên cả mô hình cây quyết định dày đặc (dense) và thưa (sparse) cho thấy:

- Kernel SHAP có hiệu quả sử dụng mẫu (sample efficiency) cao hơn.
- Giá trị giải thích của LIME có thể khác đáng kể so với giá trị SHAP, do LIME không đảm bảo đồng thời các tính chất Local Accuracy và Consistency.

5.2 Mức độ phù hợp với trực giác con người (Consistency with Human Intuition)

Định lý 1 cho thấy giá trị SHAP là nghiệm duy nhất thỏa mãn đồng thời ba tính chất mong muốn của phương pháp giải thích cộng tính. Trong khi đó, LIME và DeepLIFT có thể đưa ra các giá trị đóng góp khác với SHAP.

Để đánh giá ý nghĩa của kết quả này, tác giả tiến hành nghiên cứu người dùng trên nền tảng Amazon Mechanical Turk, với giả định rằng một phương pháp giải thích tốt nên đưa ra kết quả gần với cách con người giải thích một mô hình đơn giản.

Hai kịch bản được sử dụng:

- Mô hình chẩn đoán bệnh, trong đó điểm số bệnh phụ thuộc vào sự xuất hiện của hai triệu chứng.
- Bài toán phân chia lợi nhuận, trong đó lợi nhuận được xác định bởi giá trị lớn nhất (max) mà một trong ba người đạt được.

Trong cả hai trường hợp, người tham gia được yêu cầu phân bổ mức độ đóng góp của từng đầu vào đối với kết quả đầu ra.

Kết quả cho thấy SHAP có mức độ đồng thuận với cách giải thích của con người cao hơn đáng kể so với LIME và DeepLIFT. Đặc biệt, SHAP xử lý tốt các hàm max, vốn là một hạn chế đã được chỉ ra của DeepLIFT.


5.3 Giải thích sự khác biệt giữa các lớp (Explaining Class Differences)

Dựa trên mối liên hệ giữa DeepLIFT và SHAP tác giả đề xuất Deep SHAP, trong đó các quy tắc lan truyền của DeepLIFT được điều chỉnh để xấp xỉ giá trị SHAP tốt hơn.

Để đánh giá phương pháp, tác giả sử dụng một mạng nơ-ron tích chập (CNN) đã được huấn luyện trên bộ dữ liệu MNIST. Mạng gồm: hai lớp tích chập (convolutional layers), hai lớp kết nối đầy đủ (dense layers), và một lớp đầu ra softmax gồm 10 lớp.

Trong thí nghiệm:

- SHAP được tính bằng Kernel SHAP;
- LIME và Kernel SHAP đều sử dụng 50.000 mẫu;
- các ảnh được giải thích bằng cách xác định những pixel quan trọng nhất và lần lượt che (mask) khoảng 20% số pixel để làm thay đổi kết quả dự đoán từ chữ số 8 sang 3.



Hình 2: Các vùng màu đỏ làm tăng xác suất mô hình dự đoán thuộc lớp đó, trong khi các vùng màu xanh làm giảm xác suất của lớp đó. Hình Masked minh họa kết quả khi lần lượt che (mask) các pixel quan trọng, khiến dự đoán của mô hình thay đổi từ chữ số 8 sang chữ số 3.

Kết quả cho thấy Deep SHAP và Kernel SHAP xác định các vùng ảnh quan trọng chính xác hơn so với DeepLIFT và LIME, đồng thời việc che các pixel

được đánh giá là quan trọng bởi SHAP làm thay đổi xác suất dự đoán nhiều hơn. Điều này cho thấy việc xấp xỉ gần với giá trị SHAP giúp cải thiện chất lượng giải thích của mô hình học sâu.

Note Setup thí nghiệm

Giả sử có một ảnh MNIST mà mô hình dự đoán là: 8, 8 : 0.98, 3 : 0.01 → SHAP cho rằng các pixel nào quan trọng nhất → Sắp xếp tất cả pixel theo độ quan trọng do phương pháp đưa ra. → Bắt đầu che (mask) các pixel quan trọng nhất → Khi che đủ khoảng 20% số pixel quan trọng nhất, mô hình có thể đổi dự đoán → Khi các nét đặc trưng của số 8 bị xóa dần, mô hình sẽ cập nhật lại xác suất. 8 : 0.30, 3 : 0.61 ← lớn nhất

→ Nếu một phương pháp thực sự tìm đúng pixel quan trọng thì: Chỉ cần che một ít pixel là mô hình sẽ mất thông tin quan trọng và đổi dự đoán.

LIME – 2016

DeepLIFT – 2017

SHAP (SHapley Additive exPlanations) – 2017

Kernel SHAP – 2017

Deep SHAP – 2017

Linear SHAP – 2017

Max SHAP – 2017

TreeSHAP – 2018

GradientSHAP – 2019

SAGE (Shapley Additive Global Explanations) – 2020

Causal SHAP – 2020

GPUShap – 2021

FastSHAP – 2021

PartitionSHAP – 2022

GraphSHAP – 2023 (giải thích cho Graph Neural Networks)

TimeSHAP – tiếp tục được phát triển và ứng dụng rộng rãi cho chuỗi thời gian và mô hình tuần tự (2023–2025)

FastSHAP v2 / các biến thể FastSHAP – 2023–2024 (cải thiện tốc độ và độ chính xác)

Causal SHAP – tiếp tục được mở rộng (2023–2025) để xử lý quan hệ nhân quả thay vì chỉ dựa trên tương quan

Amortized SHAP / Learned SHAP Approximations – 2024–2025 (huấn luyện một mô hình để dự đoán SHAP thay vì tính trực tiếp)

LLM Explanation / SHAP for Foundation Models – 2024–2026 (ứng dụng SHAP để giải thích các mô hình ngôn ngữ lớn và mô hình đa phương thức)

Kể từ khi được đề xuất vào năm 2017, SHAP gần như đã trở thành chuẩn thực tế (*de facto standard*) trong các phương pháp giải thích dựa trên mức độ đóng góp của đặc trưng (*feature attribution*) nhờ nền tảng lý thuyết vững chắc và khả năng áp dụng cho nhiều loại mô hình học máy.

Các nghiên cứu sau đó chủ yếu tập trung theo bốn hướng chính:

- tăng tốc quá trình tính toán giá trị SHAP, chẳng hạn như *FastSHAP* và *GPUShap*;

- mở rộng SHAP cho các kiến trúc mô hình mới, chẳng hạn như *TreeSHAP*, *DeepSHAP* và *GraphSHAP*;
- áp dụng SHAP cho các dạng dữ liệu đặc thù như ảnh, đồ thị và chuỗi thời gian;
- khắc phục các hạn chế của SHAP, bao gồm xử lý sự phụ thuộc giữa các đặc trưng, tích hợp quan hệ nhân quả và lượng hóa độ bất định (*uncertainty*) trong quá trình giải thích.